

Análisis Exploratorio de Datos

TUSZ DataSet

Integrantes: Jorge Tito Ccahuaya
Profesor: Ana Maria Cuadros Valdivia
Fecha de realización: 5 de junio de 2025
Fecha de entrega: 5 de junio de 2025
Arequipa - Perú

Índice de Contenidos

1. Hipótesis Iniciales	1
1.1. Hipótesis 1: ¿Cómo evolucionan las señales EEG segundos antes, durante y después de una crisis epiléptica en múltiples canales?	1
1.2. Hipótesis 2: ¿Qué tan separadas están temporalmente las crisis dentro de una misma grabación?	2
1.3. Hipótesis 3: ¿Qué canales derivados muestran mayor actividad durante las crisis, y se repiten en distintos pacientes?	3
2. Fuente de datos	4
2.1. Fuente	4
2.2. Conocimiento involucrado y Área de Origen	4
2.3. Problema computacional a Resolver	5
2.4. Conocimiento en cada variable y su importancia	5
2.5. Descripción dataset	5
2.5.1. Edf file	5
2.6. Terminología	11
2.7. Columnas Importantes del Dataset	12
2.8. Unidades de Medida y su Procesamiento	12
2.9. Formato Inicial	13
2.10. Transformaciones y limpieza	13
3. Conclusiones	14
Referencias	15

Índice de Figuras

1. sesión de un paciente en crisis minuto 00:50-01:50	1
2. sesión de un paciente en crisis minuto 00:19-00:20	2
3. Cantidad de eventos de crisis por sesión	3
4. 3 eventos de crisis de la sesión de un paciente	3
5. 18 eventos de crisis de la sesión de un paciente	3

Índice de Tablas

1. Clasificación de los campos del header general según tipo de dato.	6
2. Clasificación de los campos del header por canal según tipo de dato.	8
3. Clasificación de los segmentos de señal según tipo de dato.	10

1. Hipótesis Iniciales

1.1. Hipótesis 1: ¿Cómo evolucionan las señales EEG segundos antes, durante y después de una crisis epiléptica en múltiples canales?

Motivación: Durante la visualización exploratoria se notó que los eventos de seizure generan perturbaciones visibles en los canales EEG. Esto inspiró la idea de observar cómo evoluciona la señal no solo durante el evento, sino también en los segundos previos y posteriores. Esta hipótesis permite usar visualizaciones multicanal tipo zoom para evaluar si existen cambios preictales que podrían tener valor predictivo o diagnóstico.

Plan de Análisis:

- Seleccionar una muestra de eventos en donde label = seizure
- Para cada evento, extraer una ventana de señal de -10s a +10s centrada en el evento. (parte rojo será el intervalo seizure)
- Visualizar todos los canales derivados de forma superpuesta
- De allí podemos visualizar previamente y posteriormente si hay aumento de amplitud previo, sincronía entre canales, actividad prolongada post-seizure.




Figura 1: sesión de un paciente en crisis minuto 00:50-01:50




Figura 2: sesión de un paciente en crisis minuto 00:19-00:20

1.2. Hipótesis 2: ¿Qué tan separadas están temporalmente las crisis dentro de una misma grabación?

Motivación: Durante la revisión de los archivos .csv_bi, se observó que una misma grabación puede contener múltiples eventos de seizure. Esto generó curiosidad por saber si estos eventos están agrupados en intervalos cercanos (como ráfagas) o si están bien separados en el tiempo. Comprender esta distribución puede revelar patrones clínicos y ayudar a categorizar grabaciones según su comportamiento temporal.

Plan de Análisis:

- Identificar grabaciones que contienen más de un evento label = seiz.
- Ordenar cronológicamente los eventos por start_time dentro de cada grabación.
- Calcular los intervalos de tiempo entre un evento y el siguiente.

Distribución de archivos por número de eventos seizure




Figura 3: Cantidad de eventos de crisis por sesión




Figura 4: 3 eventos de crisis de la sesión de un paciente




Figura 5: 18 eventos de crisis de la sesión de un paciente

1.3. Hipótesis 3: ¿Qué canales derivados muestran mayor actividad durante las crisis, y se repiten en distintos pacientes?

Motivación: El dataset incluye derivaciones entre pares de electrodos estándar según un montaje TCP. Al observar las señales durante eventos de crisis, parece que algunos canales presentan mayor actividad repetida. Explorar esta tendencia puede revelar patrones

topográficos comunes en crisis epilépticas y ayudar a focalizar futuros análisis o reducir la dimensionalidad de los datos.

Plan de Análisis:

- Filtrar todos los eventos label = seiz en los archivos .csv
- Para cada evento, registrar el canal asociado.
- Agrupar por canal derivado y contar con frecuencia total de aparición durante seizures.

2. Fuente de datos

2.1. Fuente

El conjunto de datos [1] utilizado en este trabajo proviene del Temple University Hospital EEG Corpus (TUH EEG Corpus), específicamente de su subcorpus TUH Seizure Corpus (TUSZ), que fue lanzado por primera vez en 2017 y actualizado periódicamente, siendo una de las colecciones públicas más extensas de electroencefalogramas (EEG) clínicos anotados. La versión utilizada en este proyecto es la v2.0.3.

La recolección de datos fue realizada por un equipo multidisciplinario del Laboratorio de Inteligencia Computacional y Bioinformática Médica de la Temple University, en colaboración con médicos neurólogos del hospital universitario. La recolección de los EEG se llevó a cabo en un entorno clínico real, en sesiones de monitoreo rutinario o de emergencia, lo cual proporciona una alta validez ecológica al conjunto de datos. Las señales fueron recolectadas con sistemas de EEG estándar, y las anotaciones de eventos (como crisis epilépticas) fueron realizadas por expertos humanos, con herramientas asistidas por software.

La técnica de recolección fue electroencefalografía multicanal, donde se colocan electrodos en el cuero cabelludo siguiendo el sistema 10-20, y se registran las diferencias de voltaje entre pares de electrodos durante un período de tiempo. Las señales capturadas se almacenaron en archivos en formato EDF (European Data Format), junto con archivos auxiliares .csv y .csv_bi con anotaciones detalladas.

2.2. Conocimiento involucrado y Área de Origen

El conocimiento involucrado en este conjunto de datos proviene principalmente de la neurociencia clínica, específicamente de la neurofisiología y la epileptología, pero también abarca aspectos de ingeniería biomédica y ciencia de la computación. A nivel computacional, este conjunto de datos permite el desarrollo de técnicas de procesamiento de señales, detección de eventos anómalos, clasificación temporal, y aprendizaje automático aplicado a datos médicos.

2.3. Problema computacional a Resolver

Desde el punto de vista computacional, el conjunto de datos se utiliza para abordar el problema de la detección automática de crisis epilépticas (seizures) en grabaciones EEG de larga duración. Este problema implica identificar con alta precisión y bajo falso positivo los intervalos temporales en los que ocurre una crisis, a partir de señales multicanal que presentan ruido, artefactos fisiológicos, y gran variabilidad entre pacientes. La resolución efectiva de este problema tiene un fuerte impacto en aplicaciones clínicas como el monitoreo continuo, el diagnóstico asistido, y el desarrollo de dispositivos portátiles para pacientes epilépticos.

2.4. Conocimiento en cada variable y su importancia

Cada grabación EEG incluye múltiples variables, las más importantes son:

- Canales EEG (EEG FP1-REF, EEG F7-REF, etc.): cada uno representa una derivación específica entre dos electrodos del cuero cabelludo. Estas señales reflejan la actividad eléctrica del cerebro en distintas regiones. Su análisis permite identificar patrones característicos de una crisis epiléptica.
- Tiempo (start_time, stop_time en segundos): permite ubicar los eventos en una línea temporal, esencial para el análisis secuencial y la localización precisa de eventos clínicos.
- Etiquetas de evento (label, típicamente 'seiz' para crisis, 'bckg' para fondo): codifican la naturaleza de los segmentos. Son fundamentales para entrenar y evaluar modelos de detección automática.
- Confianza (confidence): expresa cuán segura es la anotación, lo cual permite ponderar los eventos durante el aprendizaje automático.

Estas variables fueron capturadas porque cada una permite representar un aspecto esencial del fenómeno clínico: el espacio cerebral (canales), el tiempo (inicio-fin del evento) y la semántica del evento (etiqueta y confianza). Son indispensables para abordar tareas de modelado temporal, clasificación supervisada, y visualización clínica.

2.5. Descripción dataset

A nivel de atributos:

2.5.1. Edf file

Mostraremos una tabla que resume las características de cada variables además describimos lo que significa cada variable, lo hemos dividido en 3 secciones, la primera es la información que nos brinda el header general, el segundo es la información que podemos destacar del header de cada canal y finalmente los datos crudos que son almacenados con la lectura de cada canal.

- **Header General:** Como vemos la tabla ?? la mayoría son de tipo cualitativos sin embargo no hay le necesidad de transformarlos a numéricos ya que esta no será con la que trabajaremos directamente. Esta informacion nos sirve por ejemplo para identificar datos del paciente o datos que corresponden a la lectura de los datos, etc.

Tabla 1: Clasificación de los campos del header general según tipo de dato.

Variable / Campo	Tipo de dato	Subcategoría
version	Cualitativo	Nominal (texto)
local_patient_id	Cualitativo	Nominal (texto)
local_recording_id	Cualitativo	Nominal (texto)
start_date	Cualitativo	Ordinal (texto con estructura de fecha)
start_time	Cualitativo	Ordinal (texto con estructura de hora)
header_length	Cuantitativo	Discreto (entero)
reserved	Cualitativo	Nominal (texto libre)
num_of_data_records	Cuantitativo	Discreto (entero)
dura- tion_of_data_record	Cuantitativo	Continuo (flotante en segundos)
number_of_signals (n_signals)	Cuantitativo	Discreto (entero)

- **1. version:** Este campo indica la versión del formato EDF que sigue el archivo. Aunque todos los archivos EDF estándar usan simplemente "0" como valor, este campo es útil para comprobar la conformidad con la especificación del formato y detectar variantes como EDF+ que podrían tener anotaciones adicionales. En resumen, sirve como marca de validación estructural básica del archivo.
- **2. local_patient_id:** Este campo contiene una cadena de texto con información relacionada al paciente, aunque suele estar anonimizada por razones éticas. Puede incluir un identificador interno, edad, sexo o iniciales. Por ejemplo, un valor como "X021 M 29" podría indicar al paciente anónimo X021, masculino, de 29 años. Últimamente este campo generalmente ha sido limpiado para proteger la privacidad.
- **3. local_recording_id:** En este campo se almacena información sobre la grabación específica, como el tipo de estudio, el dispositivo usado, o el montaje del EEG. Por ejemplo, EEG 03_tcp_ar_a indica que se usó el montaje referencial tipo AR-A. Esta información contextualiza el origen y propósito de la grabación, y puede ser útil para segmentar o agrupar archivos por tipo de adquisición.
- **4. start_date:** Representa la fecha en que se inició la grabación del EEG, en el formato texto "dd.mm.yy". Aunque es un texto, se considera un dato ordinal, ya que tiene un orden cronológico natural. Un ejemplo sería "15.03.19", que indica que

la grabación comenzó el 15 de marzo de 2019.

- **5. start_time:** Este campo indica la hora exacta en que comenzó la adquisición de datos, en el formato "hh.mm.ss". Al igual que la fecha, también es ordinal. Por ejemplo, "08.45.00" señala que la grabación se inició a las 8:45 a.m.
 - **6. header_length:** Indica cuántos bytes ocupa todo el encabezado del archivo EDF, incluyendo el bloque global y los headers de canal. El valor debe ser múltiplo de 256, ya que cada canal adicional agrega 256 bytes. Por ejemplo, un valor de 5120 bytes corresponde a un header global de 256 bytes más 19 canales (19×256). Este valor permite calcular dónde empieza la señal binaria en el archivo.
 - **7. reserved:** Campo reservado para usos futuros o personalizados. No tiene una estructura fija y puede estar completamente vacío o contener texto definido por el fabricante o anotaciones específicas del software que generó el archivo. Por ejemplo, en el estándar EDF+ se puede encontrar EDF+C para indicar que el archivo contiene anotaciones clínicas codificadas como canales especiales.
 - **8. number_of_data_records:** Este campo indica la cantidad total de registros de datos (o segmentos) en el archivo. Cada uno de estos registros tiene una duración fija especificada en otro campo. Por ejemplo, si el valor es 3600 y cada registro dura 1 segundo, el archivo contiene 1 hora de datos. En variantes como EDF+, un valor de -1 puede usarse para indicar longitud variable o indefinida.
 - **9. duration_of_data_record:** Especifica la duración en segundos de cada bloque o registro de datos. Este valor puede ser un número decimal (flotante) como 1.0, 0.5, etc., lo cual determina la resolución temporal del archivo en bloques. Si hay 3600 registros y cada uno dura 1.0 segundo, el total de la grabación es de una hora. Este campo es crucial para reconstruir correctamente el eje temporal de la señal.
 - **10. number_of_signals (n_signals):** Este campo indica cuántas señales o canales distintos se registraron en el archivo. En un EEG clínico convencional, este número suele variar entre 19 y 30, incluyendo canales fisiológicos (EEG, ECG, EOG) y posibles canales de anotación. Por ejemplo, un valor de 23 podría indicar 21 canales EEG más 2 de referencia. Esta información es esencial para leer correctamente los headers de canal y la matriz de datos.
- **Header de cada Canal:** Vamos ahora con los headers de cada canal en un archivo .edf, que vienen justo después del header global. Como sabemos, cada canal aporta 256 bytes, y hay *n_signals* canales (según el campo del header global).

Tabla 2: Clasificación de los campos del header por canal según tipo de dato.

Campo / Variable	Tipo de dato	Subcategoría
label	Cualitativo	Nominal (texto)
transducer_type	Cualitativo	Nominal (texto)
physical_dimension	Cualitativo	Nominal (unidad de medida textual)
physical_min	Cuantitativo	Continuo (número flotante)
physical_max	Cuantitativo	Continuo (número flotante)
digital_min	Cuantitativo	Discreto (entero)
digital_max	Cuantitativo	Discreto (entero)
prefiltering	Cualitativo	Nominal u ordinal (texto estructurado) ^a
samples_per_record	Cuantitativo	Discreto (entero)
reserved	Cualitativo	Nominal (texto libre)

^a Puede incluir orden en las configuraciones de filtros: HP, LP, Notch, etc.

A continuación mostramos la descripción de cada variable:

- **1. label:** Este campo es una cadena de texto que identifica el nombre del canal o señal. Por ejemplo, EEG FP1-REF o ECG. Es un dato cualitativo nominal, ya que nombra la fuente de la señal sin ningún orden inherente. Es fundamental para saber qué tipo de actividad se está midiendo y para alinear canales entre diferentes grabaciones o estándares de montaje.
- **2. transducer_type:** Este campo describe el tipo de transductor o electrodo utilizado para captar la señal, como AgCl electrode, surface o depth. También es un dato cualitativo nominal. Aunque a menudo se deja vacío o se rellena de forma genérica, es útil para distinguir entre técnicas de adquisición distintas.
- **3. physical_dimension:** Indica la unidad física de la señal grabada, como μV (microvoltios), mV, Ohm, etc. Se trata de un dato cualitativo nominal. Este campo es clave para interpretar correctamente el valor físico de cada muestra y evitar errores al comparar señales de diferentes canales o archivos. En EEG, lo habitual es encontrar μV .
- **4. physical_min:** Este campo especifica el valor físico mínimo que puede representar el canal tras el escalado desde valores digitales. Es un dato cuantitativo continuo, usualmente en flotante. Por ejemplo, un canal podría tener $-500.0 \mu V$ como mínimo físico. Junto con physical_max, define el rango de voltajes reales captados.
- **5. physical_max:** Complementario al anterior, este campo indica el valor físico máximo representable tras el escalado. También es cuantitativo continuo. Por

ejemplo, si el canal va de -500.0 a $+500.0$ μV , este campo tendrá 500.0 . Estos dos extremos permiten mapear los datos digitales a sus valores reales físicos.

- **6. digital_min:** Es el valor entero más bajo que puede tomar una muestra digitalizada en este canal, antes de la conversión a unidades físicas. Es un dato cuantitativo discreto (entero). Normalmente está en el rango de -32768 , lo cual corresponde al límite de un entero con signo en 16 bits. Es esencial para la fórmula de conversión.
- **7. digital_max:** Valor entero máximo que puede representar el conversor A/D para este canal. También es cuantitativo discreto. Usualmente es $+32767$ en EEG digitalizado a 16 bits. Junto con `digital_min`, define la escala de digitalización del canal. La relación entre valores físicos y digitales depende directamente de estos dos campos.
- **8. prefiltering:** Campo textual que describe el filtrado previo que se le aplicó a la señal antes de guardarla, como `HP:0.1Hz LP:70Hz`. Es cualitativo nominal u ordinal, dependiendo de si indica frecuencias específicas. Nos ayuda a entender por qué ciertas componentes están ausentes en la señal cruda, como bajas frecuencias filtradas para reducir artefactos.
- **9. samples_per_record:** Indica cuántas muestras hay por cada registro de datos en este canal. Es cuantitativo discreto. Por ejemplo, si cada registro dura 1 segundo y este valor es 256, entonces el canal tiene una frecuencia de muestreo de 256 Hz. Este campo puede variar entre canales.
- **10. reserved:** Campo reservado sin uso definido, codificado como texto. Es cualitativo nominal y frecuentemente está vacío o contiene texto genérico. Aunque no se usa en la mayoría de los casos, algunos sistemas propietarios podrían emplearlo para codificar metadatos específicos, así que conviene no descartarlo automáticamente.

• Registros de cada Canal:

Variable: Muestras digitales por canal (señal cruda): Los datos crudos en un archivo `.edf` son una secuencia continua de muestras digitalizadas, organizadas por registros de datos. Cada muestra representa el valor de la señal en un instante de tiempo para un canal determinado, y está codificada típicamente como un número entero de 16 bits con signo (`int16`). Estas muestras están intercaladas por canal y ordenadas por bloques (registros), y cada bloque tiene una duración fija especificada en el header (`duration_of_data_record`). Por ejemplo, si tenemos 30 canales y cada registro contiene 256 muestras por canal, cada bloque ocupa 7680 valores (30×256). Esta información es cuantitativa, discreta a nivel de almacenamiento (valores enteros), pero se interpreta como cuantitativa continua una vez que se convierte a unidades físicas como μV . La conversión se realiza mediante una transformación lineal usando los campos `physical_min`, `physical_max`, `digital_min`, y `digital_max` de cada canal.

Tipo de dato: es un `int16` por cada muestra y su tipo general es **uantitativo** con una subcategoría **Discreto**, luego **Continuo** tras conversión física, generalmente entre

-32768 y +32767 antes del escalado.

Conversión a unidades físicas: La transformación de cada muestra digital D a un valor físico P se realiza con:

$$P = \left(\frac{D - D_{min}}{D_{max} - D_{min}} \right) (P_{max} - P_{min}) + P_{min}$$

Donde:

- D = valor digital leído.
- D_{min} , D_{max} = valores mínimos y máximos digitales de cada canal.
- P_{min} , P_{max} valores mínimos y máximos físicos de cada canal.

Tabla 3: Clasificación de los segmentos de señal según tipo de dato.

Variable / Segmento	Tipo de dato	Subcategoría
Muestras digitales (<code>int16</code>)	Cuantitativo	Discreto (almacenado)
Muestras convertidas (microvoltios)	Cuantitativo	Continuo (analizado)

Finalmente los bytes restantes nos brinda las muestras de cada registro de cada canal por el número de registros brindados en el header principal, cabe recalcar que cada muestra en un registro dado son enteros de 16 bits.

A nivel de registros

- **.edf:** Para este formato no podemos hablar que un registro se representa como una fila, debido a la variedad de las frecuencias de cada canal, pero hay algo que debemos de tener en cuenta, en el header general, mas precisamente entre los bytes 236 y 243 hay un campo que nos devuelve el número de registros totales, entonces ¿A qué se refiere este registro?, este registro se refiere al total de muestras que se obtienes por unidad de tiempo, por ejemplo, si el canal 1 tiene una frecuencia de 250hz, entonces un registro consistirá en una muestra de 250 enteros de 16 bits. Luego considerando que todos los canales tienen la misma frecuencia entonces allí si podemos hablar de un registro como unidad mínima el cual consistiría de un instante de tiempo y n_ch columnas que indicarían la lectura que se le haga a un canal en particular.
- **.csv:** Este archivo nos proporciona las anotaciones clínicas identificados en la señal EEG contenida en el archivo .edf. En este archivo si podemos hablar de un registro y para decir lo que nos representan pongamos un ejemplo de registro: *EEG F7-REF, 124.0, 156.0, cpsz, 1.0*, este nos quiere decir que en el canal *EEGF7 – REF*, entre los segundos 124 y 156 de la señal, se detectó una crisis epiléptica de tipo *cpsz* con confianza total 1.0.

- **.csv_bi** Algo muy similar ocurre con este archivo que también es el asociado a su .edf con la única diferencia que aquí hace referencia a todos los canales, por ejemplo tenemos *TERM,36.8868,237.2101,seiz,1.0*, esto nos quiere decir que entre todos los canales, entre los segundos 36.8868 y 237.2101 de señal se ha detectado una crisis epiléptica con confianza total de 1.0.

Hay Granularidad ?

El conjunto de datos TUSZ presenta un alto nivel de granularidad temporal, ya que cada archivo .edf contiene señales EEG muestreadas típicamente a 250 Hz, lo que equivale a 250 muestras por segundo por canal. Esto significa que en un registro de solo 10 segundos, se capturan 2,500 puntos de datos por canal, y considerando que cada grabación puede incluir entre 19 y 27 canales, la cantidad total de muestras por segundo se multiplica rápidamente. Este nivel de detalle permite analizar con precisión los cambios sutiles en la actividad cerebral, facilitando el estudio de eventos transitorios como las crisis epilépticas, cuya detección depende de patrones morfológicos que ocurren en ventanas de milisegundos. Así, el acceso a esta granularidad por muestra resulta esencial para tareas de modelado temporal, detección fina de eventos, y visualización precisa de la señal EEG.

2.6. Terminología

Terminología Especial Utilizada en el Conjunto de Datos El conjunto de datos TUSZ emplea terminología propia del campo de la neurofisiología clínica. A continuación se definen los términos clave:

- EEG (Electroencefalograma): registro de la actividad eléctrica cerebral obtenido mediante electrodos colocados en el cuero cabelludo.
- Canal: derivación entre dos electrodos (ej. FP1-REF) que mide la diferencia de potencial eléctrico entre ambas ubicaciones.
- Evento Seizure (seiz): episodio de actividad eléctrica anormal en el cerebro, asociado a una crisis epiléptica.
- Artefacto (artf): señal no cerebral (como parpadeos, movimientos o ruido del equipo) que contamina el EEG.
- Background (bckg): actividad cerebral de fondo sin interés clínico específico.
- Montaje: configuración de derivaciones utilizadas (ej. referencial, bipolar). En TUSZ se usan montajes como tcp_ar, tcp_le, etc.
- Frecuencia de muestreo: número de muestras por segundo (comúnmente 250 Hz en TUSZ).
- EDF (European Data Format): formato estandarizado para almacenar señales bio-médicas multicanal.

2.7. Columnas Importantes del Dataset

El dataset incluye archivos .edf, .csv y .csv_bi. Las columnas relevantes son: **En los archivos .csv:**

- channel: nombre del canal EEG donde se detectó el evento.
- start_time y stop_time (segundos): delimitan el intervalo temporal del evento.
- label: tipo de evento (e.g. seiz, bckg, artf).
- confidence: nivel de certeza de la anotación (en rango [0.0, 1.0]).

Estas columnas son especialmente importantes para las hipótesis que abordan la distribución temporal de las crisis y el análisis de los canales más involucrados, ya que permiten cuantificar y localizar los eventos de interés.

En los archivos .edf (derivado del header):

- physical_min y physical_max: rangos físicos en μV (microvoltios).
- digital_min y digital_max: valores enteros utilizados internamente en la codificación binaria.
- samples_per_record: número de muestras por segmento.
- label de cada canal: identifica la región cerebral asociada a la derivación.

2.8. Unidades de Medida y su Procesamiento

Los valores en las señales EEG están codificados en valores digitales (int16) que deben ser convertidos a valores físicos en microvoltios (μV) usando la fórmula: **Conversión a unidades físicas:** La transformación de cada muestra digital D a un valor físico P se realiza con:

$$P = \left(\frac{D - D_{min}}{D_{max} - D_{min}} \right) (P_{max} - P_{min}) + P_{min}$$

Donde:

- D = valor digital leído.
- D_{min}, D_{max} = valores mínimos y máximos digitales de cada canal.
- P_{min}, P_{max} = valores mínimos y máximos físicos de cada canal.

En los artículos científicos, esta conversión es esencial antes de aplicar análisis estadísticos, entrenamiento de modelos o visualizaciones, ya que permite interpretar los valores en términos neurofisiológicos reales. Algunos artículos optan por normalizar los datos por canal (z-score o min-max), mientras que otros los usan directamente en unidades físicas si el modelo lo permite.

2.9. Formato Inicial

El conjunto de datos original se encuentra en el formato EDF (European Data Format), un estándar ampliamente utilizado para almacenar señales biomédicas multicanal como EEG, EKG, EMG, entre otras. Cada archivo .edf contiene la señal cruda en forma de valores digitales (int16) por canal, junto con un encabezado general de 256 bytes y un bloque de encabezados de canal que describe el nombre del canal, las unidades físicas, la frecuencia de muestreo, y los límites de conversión digital a física.

Además, cada archivo .edf está acompañado por uno o dos archivos auxiliares en formato CSV:

Un archivo .csv con las anotaciones manuales de eventos clínicos, que incluye columnas como channel, start_time, stop_time, label y confidence.

Un archivo opcional .csv_bi que contiene seizure en un intervalos para todos los montajes.

Estos archivos en conjunto permiten tanto el análisis computacional de las señales EEG como la alineación precisa con eventos neurológicos relevantes.

2.10. Transformaciones y limpieza

Para convertir las señales EEG originales en un formato utilizable para el análisis computacional, se aplicaron diversas transformaciones de preprocesamiento orientadas a la limpieza del ruido, preservación de la señal cerebral relevante y eliminación de artefactos no neuronales.

Primero, se aplicó un filtro pasabanda entre 0.5 y 100 Hz, el cual permitió conservar solo las frecuencias cerebrales relevantes (delta, theta, alpha, beta y gamma) y eliminar tanto las oscilaciones lentas (<0.5 Hz), asociadas a movimientos corporales o respiración, como las rápidas (>100 Hz), relacionadas con ruido muscular o interferencias del entorno. Esta etapa redujo el contenido no informativo de la señal.

En segundo lugar, se utilizó un filtro notch centrado en 60 Hz, diseñado específicamente para eliminar la interferencia provocada por la red eléctrica. Este tipo de ruido se manifiesta como una oscilación de alta frecuencia que no proviene de la actividad cerebral, sino de fuentes externas como cables o iluminación, y es común en entornos clínicos.

Finalmente, se implementó un proceso de eliminación de segmentos por umbral de amplitud extrema, descartando tramos donde la señal superaba los 500 μV . Este valor límite se definió a partir de literatura clínica y fue empleado como criterio para identificar artefactos fisiológicos (como parpadeos o micromovimientos) y ruido técnico que distorsionan la interpretación de la señal. Si un canal superaba este umbral durante un segundo determinado, dicho segmento era eliminado del análisis.

Estas transformaciones permitieron obtener señales EEG más limpias y estables, aptas para visualización, análisis temporal y modelado computacional.

3. Conclusiones

Para la Hipótesis 1, Las visualizaciones multicanal centradas en los eventos de crisis revelaron una evolución morfológica clara en la señal EEG. En los segundos previos al inicio de una crisis se observaron variaciones graduales en la amplitud y la frecuencia de ciertos canales, seguidos por un aumento abrupto de actividad durante el evento, con patrones típicos como descargas rítmicas o picos repetitivos. Posteriormente, muchos canales mostraron una fase de recuperación caracterizada por disminución progresiva de la amplitud y retorno al patrón basal. Estos hallazgos respaldan la utilidad de enfoques que analicen secuencias temporales extendidas alrededor del evento y confirman que la información relevante para la detección no se limita únicamente al intervalo de crisis, sino también a su contexto temporal.

Para la Hipótesis 2, El análisis exploratorio mediante visualizaciones de líneas de tiempo por archivo agrupadas por cantidad de eventos mostró que, en grabaciones con múltiples crisis, los eventos pueden presentarse tanto de forma agrupada en cortos intervalos como dispersos a lo largo de toda la grabación. Esta variabilidad sugiere que no existe un patrón temporal fijo entre eventos dentro de una misma sesión, lo cual tiene implicancias importantes para el diseño de modelos predictivos y estrategias de segmentación, ya que obliga a considerar ventanas de observación más amplias y adaptativas.

Referencias

- [1] Shah, V., Von Weltin, E., Lopez, S., McHugh, J. R., Veloso, L., Golmohammadi, M., Obeid, I., y Picone, J., “The temple university hospital seizure detection corpus”, *Frontiers in neuroinformatics*, vol. 12, p. 83, 2018.