

Análisis Exploratorio de Datos - Data Wrangling

TUSZ DataSet

Integrantes: Jorge Tito Ccahuaya
Profesor: Ana Maria Cuadros Valdivia
Fecha de realización: 4 de junio de 2025
Fecha de entrega: 4 de junio de 2025
Arequipa - Perú

Índice de Contenidos

1. TUSZ dataset	1
2. Análisis del comportamiento de los datos	3
2.1. Descripción de un registro	3
2.2. ¿Cuántos registros hay?	4
2.3. ¿Qué datos son discretos y cuáles continuos?	8
2.3.1. Edf file	8
2.3.2. csv file	12
2.3.3. csv_bi file	12

Índice de Figuras

1. Estructura general del dataset TUSZ	1
2. Distribución de registros en archivos .edf por cada partición	5
3. Distribución de registros en archivos .csv por cada partición	5
4. Distribución de registros en archivos .csv_bi por cada partición	6
5. Relación de la distribución de registros por cada partición	6
6. Distribución del tamaño de archivos .edf en el dataset TUSZ	7

Índice de Tablas

1. Estructura del header general en un archivo EDF.	2
2. Estructura del header por canal en un archivo EDF.	3
3. Cantidad de registros por cada archivo y para cada partición del dataset TUSZ.	4
4. Clasificación de los campos del header general según tipo de dato.	8
5. Clasificación de los campos del header por canal según tipo de dato.	10
6. Clasificación de los segmentos de señal según tipo de dato.	12

1. TUSZ dataset

Antes de poder responder las preguntas es importante mencionar su estructura general. Está dividido en 3 carpetas principales **train**, **dev** y **eval**, cada una de ellas va a tener una lista de carpetas de pacientes(también estructurada en carpetas), luego cada paciente tiene una o varias carpetas de sesiones, cada sesión puede tener alguna de las configuraciones que tiene: 01_tcp_ar, 02_tcp_le, 03_tcp_ar_a, luego cada configuración puede tener una o varias tomas, una toma se representa con 3 archivos, es decir, si hay 3 tomas entonces habrá 9 archivos. Cada archivo tiene las siguientes extensiones: .edf, .csv y .csv_bi Figura (1).




Figura 1: Estructura general del dataset TUSZ

En el repositorio explícitamente nos dicen que existen los tres directorios: train, dev y eval. El directorio train contiene datos que se puedes usar para el desarrollo de alguna tecnología. Los datos dev son independientes del conjunto de entrenamiento y solo deben usarse para pruebas. Eval es un conjunto de evaluación ciega; nunca debes optimizar los parámetros en este conjunto.

Una vez que ya sabemos la estructura del dataset TUSZ nos damos cuenta que dentro de cada configuración existen por cada toma 3 archivos, dos de ellos están con la extensión .edf y el último con la extensión .edf. Dado que el contenido de este último esta en binario, quiero mostrar la estructura global.

Los primeros 256 bytes corresponden al header general Tabla (1) y contienen la siguiente información:

Tabla 1: Estructura del header general en un archivo EDF.

Campo	Bytes	Longitud	Comentario
Versión EDF	0–7	8	Versión del formato EDF
Información del paciente	8–87	80	Identificación local del paciente
Información del estudio	88–167	80	Identificación de la grabación o estudio
Fecha de inicio	168–175	8	Fecha en formato dd.mm.yy
Hora de inicio	176–183	8	Hora en formato hh.mm.ss
Longitud del header	184–191	8	Número total de bytes del header
Reservado	192–235	44	Campo reservado (uso libre) ^a
Número de registros	236–243	8	Cantidad de bloques de datos o registros
Duración por registro	244–251	8	Duración (en segundos) de cada registro de datos
Número de canales	252–255	4	Cantidad total de señales (canales EEG)

^a A veces se usan para etiquetas como EDF+C, EDF+D, etc.

Entre los bytes 252 y 255 vemos que nos informa acerca del número de canales que lo llamaremos n_ch que tiene este archivo .edf, luego los $256 * n_ch$ bytes siguientes corresponden a los headers de cada canal, la Tabla (2) muestra la información que tiene dicho header.

Tabla 2: Estructura del header por canal en un archivo EDF.

Campo	Bytes	Longitud	Comentario
Label	0–15	16	Nombre del canal (ej. EEG F3-REF)
Tipo de transductor	16–95	80	Tipo de sensor o transductor utilizado
Unidad física	96–103	8	Unidad de medida (ej. uV, mV)
Mínimo físico	104–111	8	Valor físico mínimo correspondiente al mínimo digital
Máximo físico	112–119	8	Valor físico máximo correspondiente al máximo digital
Mínimo digital	120–127	8	Valor digital mínimo (típicamente -32768)
Máximo digital	128–135	8	Valor digital máximo (típicamente +32767)
Pre-filtrado	136–215	80	Información sobre filtros aplicados antes del almacenamiento ^a
Muestras por registro	216–223	8	Número de muestras por bloque de datos
Reservado	224–255	32	Campo reservado para uso futuro
Total	0–255	256	Tamaño total del header por canal

^a Puede incluir información como “HP:0.1Hz LP:75Hz Notch:60Hz”.

Finalmente los bytes restantes nos brinda las muestras de cada registro de cada canal por el número de registros brindados en el header principal, cabe recalcar que cada muestra en un registro dado son enteros de 16 bits.

Los archivos restantes .csv y .csv_bi serán abordados en las preguntas que se hagan mas abajo.

2. Análisis del comportamiento de los datos

2.1. Descripción de un registro

- **.edf:** Para este formato no podemos hablar que un registro se representa como una fila, debido a la variedad de las frecuencias de cada canal, pero hay algo que debemos de tener en cuenta, en el header general, mas precisamente entre los bytes 236 y 243 hay un campo que nos devuelve el número de registros totales, entonces ¿A qué se refiere este registro?, este registro se refiere al total de muestras que se obtienes por unidad de tiempo, por ejemplo, si el canal 1 tiene una frecuencia de 250hz , entonces un registro consistirá en una muestra de 250 enteros de 16 bits. Luego considerando que todos

los canales tienen la misma frecuencia entonces allí si podemos hablar de un registro como unidad mínima el cual consistiría de un instante de tiempo y n_ch columnas que indicarían la lectura que se le haga a un canal en particular.

- **.csv:** Este archivo nos proporciona las anotaciones clínicas identificados en la señal EEG contenida en el archivo .edf. En este archivo si podemos hablar de un registro y para decir lo que nos representan pongamos un ejemplo de registro: *EEG F7-REF, 124.0, 156.0, cpsz, 1.0*, este nos quiere decir que en el canal *EEGF7-REF*, entre los segundos 124 y 156 de la señal, se detectó una crisis epiléptica de tipo *cpsz* con confianza total 1.0.
- **.csv_bi** Algo muy similar ocurre con este archivo que tambien es el asociado a su .edf con la única diferencia que aquí hace referencia a todos los canales, por ejemplo tenemos *TERM,36.8868,237.2101,seiz,1.0*, esto nos quiere decir que entre todos los canales, entre los segundos 36.8868 y 237.2101 de señal se ha detectado una crisis epileptica con confianza total de 1.0.

2.2. ¿Cuántos registros hay?

A continuación vamos a hacer un recorrido sobre toda la estructura del dataset y para cada partición vamos a contar el número total de registros que hay sobre las 3 extensiones. Se utilizó un gráfico de barras horizontales (bar plot) para representar esta información, ya que este tipo de gráfica permite comparar fácilmente las cantidades absolutas entre distintas categorías discretas (en este caso, tipos de particiones). Además de manera global mostramos en la tabla ?? el conteo total.

Tabla 3: Cantidad de registros por cada archivo y para cada partición del dataset TUSZ.

Subset	.edf	.csv	.csv_bi
train	3,277,229	149,080	6,213
dev	1,567,972	26,537	2,582
eval	459,481	7,416	1,139
Total	5,304,682	183,033	9,934

02.01.- ¿Son demasiado pocos?

La Figura 2 muestra la cantidad de registros que hay sobre cada partición; vemos claramente que hay una relación proporcional respecto a la cantidad de pacientes que hay sobre cada partición.




Figura 2: Distribución de registros en archivos .edf por cada partición

La Figura 3, como mencionamos antes, representa las etiquetas que se le dan sobre cada canal si en caso ha sucedido algún evento epiléptico, y vemos que en comparación con la cantidad de registros .edf son menos, ya que estas representan etiquetas.




Figura 3: Distribución de registros en archivos .csv por cada partición

La Figura 4 como vemos, representa una menor cantidad respecto a los registros en los archivos .csv, ya que estas anotaciones son hechas por todos los canales en general.




Figura 4: Distribución de registros en archivos .csv_bi por cada partición

Finalmente, en la Figura 5 vemos la relación de cada extensión sobre cada partición.




Figura 5: Relación de la distribución de registros por cada partición

02.02.- ¿Son muchos y no tenemos Capacidad (CPU+RAM) suficiente para procesarlo?

Aunque el dataset completo es grande (aproximadamente 80 GB), la estrategia de procesar un archivo a la vez nos permite trabajar de manera eficiente sin requerir una gran cantidad de RAM como vemos en el gráfico 6. No intentamos cargar todos los archivos simultáneamente, sino que usamos una lectura secuencial. Por tanto, nuestra capacidad actual (CPU+RAM) es suficiente para el enfoque que estamos aplicando.

El siguiente gráfico 6 se muestra un boxplot que resume la distribución del tamaño de los archivos .edf en el dataset TUSZ, expresado en megabytes (MB). Esta representación permite visualizar de manera compacta la mediana, los rangos intercuartílicos y la presencia de outliers. La línea roja dentro de la caja corresponde a la mediana, mientras que los límites de la caja representan el rango donde se concentra el 50 % de los archivos. En este caso, la caja se encuentra muy comprimida en la parte inferior del eje vertical, indicando que la mayoría de los archivos son relativamente pequeños. Sin embargo, se observa una cola larga hacia la derecha compuesta por numerosos valores atípicos (outliers), algunos de los cuales superan los 700 MB.




Figura 6: Distribución del tamaño de archivos .edf en el dataset TUSZ

02.03.- ¿Hay archivos .edf duplicados? Dada la estructura del dataset vemos que no es posible encontrar archivos .edf repetidos ya que cada archivo .edf esta compuesto por la concatenación del nombre del paciente, por el tipo de sesión, por lo tanto para que hay

una duplicación de archivos .edf como mínimo tendría que haber dos usuarios repetidos, sin embargo al hacer una inspección en el dataset vemos que todas las cadenas que representan a un paciente son diferentes.

2.3. ¿Qué datos son discretos y cuáles continuos?

Para abordar esta subsección vamos a dividir en otras 3 subsecciones analizando cada extensión, recordemos que básicamente todo nuestro corpus contiene estos 3 archivos.

2.3.1. Edf file

Mostraremos una tabla que resume las características de cada variable además describimos lo que significa cada variable, lo hemos dividido en 3 secciones, la primera es la información que nos brinda el header general, el segundo es la información que podemos destacar del header de cada canal y finalmente los datos crudos que son almacenados con la lectura de cada canal.

- **Header General:** Como vemos la tabla ?? la mayoría son de tipo cualitativos sin embargo no hay necesidad de transformarlos a numéricos ya que esta no será con la que trabajaremos directamente. Esta información nos sirve por ejemplo para identificar datos del paciente o datos que corresponden a la lectura de los datos, etc.

Tabla 4: Clasificación de los campos del header general según tipo de dato.

Variable / Campo	Tipo de dato	Subcategoría
version	Cualitativo	Nominal (texto)
local_patient_id	Cualitativo	Nominal (texto)
local_recording_id	Cualitativo	Nominal (texto)
start_date	Cualitativo	Ordinal (texto con estructura de fecha)
start_time	Cualitativo	Ordinal (texto con estructura de hora)
header_length	Cuantitativo	Discreto (entero)
reserved	Cualitativo	Nominal (texto libre)
num_of_data_records	Cuantitativo	Discreto (entero)
duration_of_data_record	Cuantitativo	Continuo (flotante en segundos)
number_of_signals (n_signals)	Cuantitativo	Discreto (entero)

- **1. version:** Este campo indica la versión del formato EDF que sigue el archivo. Aunque todos los archivos EDF estándar usan simplemente "0" como valor, este

campo es útil para comprobar la conformidad con la especificación del formato y detectar variantes como EDF+ que podrían tener anotaciones adicionales. En resumen, sirve como marca de validación estructural básica del archivo.

- **2. local_patient_id:** Este campo contiene una cadena de texto con información relacionada al paciente, aunque suele estar anonimizada por razones éticas. Puede incluir un identificador interno, edad, sexo o iniciales. Por ejemplo, un valor como "X021 M 29" podría indicar al paciente anónimo X021, masculino, de 29 años. Últimamente este campo generalmente ha sido limpiado para proteger la privacidad.
- **3. local_recording_id:** En este campo se almacena información sobre la grabación específica, como el tipo de estudio, el dispositivo usado, o el montaje del EEG. Por ejemplo, EEG 03_tcp_ar_a indica que se usó el montaje referencial tipo AR-A. Esta información contextualiza el origen y propósito de la grabación, y puede ser útil para segmentar o agrupar archivos por tipo de adquisición.
- **4. start_date:** Representa la fecha en que se inició la grabación del EEG, en el formato texto "dd.mm.yy". Aunque es un texto, se considera un dato ordinal, ya que tiene un orden cronológico natural. Un ejemplo sería "15.03.19", que indica que la grabación comenzó el 15 de marzo de 2019.
- **5. start_time:** Este campo indica la hora exacta en que comenzó la adquisición de datos, en el formato "hh.mm.ss". Al igual que la fecha, también es ordinal. Por ejemplo, "08.45.00" señala que la grabación se inició a las 8:45 a.m.
- **6. header_length:** Indica cuántos bytes ocupa todo el encabezado del archivo EDF, incluyendo el bloque global y los headers de canal. El valor debe ser múltiplo de 256, ya que cada canal adicional agrega 256 bytes. Por ejemplo, un valor de 5120 bytes corresponde a un header global de 256 bytes más 19 canales (19×256). Este valor permite calcular dónde empieza la señal binaria en el archivo.
- **7. reserved:** Campo reservado para usos futuros o personalizados. No tiene una estructura fija y puede estar completamente vacío o contener texto definido por el fabricante o anotaciones específicas del software que generó el archivo. Por ejemplo, en el estándar EDF+ se puede encontrar EDF+C para indicar que el archivo contiene anotaciones clínicas codificadas como canales especiales.
- **8. number_of_data_records:** Este campo indica la cantidad total de registros de datos (o segmentos) en el archivo. Cada uno de estos registros tiene una duración fija especificada en otro campo. Por ejemplo, si el valor es 3600 y cada registro dura 1 segundo, el archivo contiene 1 hora de datos. En variantes como EDF+, un valor de -1 puede usarse para indicar longitud variable o indefinida.
- **9. duration_of_data_record:** Especifica la duración en segundos de cada bloque o registro de datos. Este valor puede ser un número decimal (flotante) como 1.0, 0.5, etc., lo cual determina la resolución temporal del archivo en bloques. Si hay 3600 registros y cada uno dura 1.0 segundo, el total de la grabación es de una hora. Este campo es crucial para reconstruir correctamente el eje temporal de la señal.

- **10. number_of_signals (n_signals):** Este campo indica cuántas señales o canales distintos se registraron en el archivo. En un EEG clínico convencional, este número suele variar entre 19 y 30, incluyendo canales fisiológicos (EEG, ECG, EOG) y posibles canales de anotación. Por ejemplo, un valor de 23 podría indicar 21 canales EEG más 2 de referencia. Esta información es esencial para leer correctamente los headers de canal y la matriz de datos.
- **Header de cada Canal:** Vamos ahora con los headers de cada canal en un archivo .edf, que vienen justo después del header global. Como sabemos, cada canal aporta 256 bytes, y hay *n_signals* canales (según el campo del header global).

Tabla 5: Clasificación de los campos del header por canal según tipo de dato.

Campo / Variable	Tipo de dato	Subcategoría
label	Cualitativo	Nominal (texto)
transducer_type	Cualitativo	Nominal (texto)
physical_dimension	Cualitativo	Nominal (unidad de medida textual)
physical_min	Cuantitativo	Continuo (número flotante)
physical_max	Cuantitativo	Continuo (número flotante)
digital_min	Cuantitativo	Discreto (entero)
digital_max	Cuantitativo	Discreto (entero)
prefiltering	Cualitativo	Nominal u ordinal (texto estructurado) ^a
samples_per_record	Cuantitativo	Discreto (entero)
reserved	Cualitativo	Nominal (texto libre)

^a Puede incluir orden en las configuraciones de filtros: HP, LP, Notch, etc.

A continuación mostramos la descripción de cada variable:

- **1. label:** Este campo es una cadena de texto que identifica el nombre del canal o señal. Por ejemplo, EEG FP1-REF o ECG. Es un dato cualitativo nominal, ya que nombra la fuente de la señal sin ningún orden inherente. Es fundamental para saber qué tipo de actividad se está midiendo y para alinear canales entre diferentes grabaciones o estándares de montaje.
- **2. transducer_type:** Este campo describe el tipo de transductor o electrodo utilizado para captar la señal, como AgCl electrode, surface o depth. También es un dato cualitativo nominal. Aunque a menudo se deja vacío o se rellena de forma genérica, es útil para distinguir entre técnicas de adquisición distintas.
- **3. physical_dimension:** Indica la unidad física de la señal grabada, como μV (microvoltios), mV, Ohm, etc. Se trata de un dato cualitativo nominal. Este campo

es clave para interpretar correctamente el valor físico de cada muestra y evitar errores al comparar señales de diferentes canales o archivos. En EEG, lo habitual es encontrar μV .

- **4. physical_min:** Este campo especifica el valor físico mínimo que puede representar el canal tras el escalado desde valores digitales. Es un dato cuantitativo continuo, usualmente en flotante. Por ejemplo, un canal podría tener $-500.0 \mu V$ como mínimo físico. Junto con `physical_max`, define el rango de voltajes reales captados.
- **5. physical_max:** Complementario al anterior, este campo indica el valor físico máximo representable tras el escalado. También es cuantitativo continuo. Por ejemplo, si el canal va de -500.0 a $+500.0 \mu V$, este campo tendrá 500.0 . Estos dos extremos permiten mapear los datos digitales a sus valores reales físicos.
- **6. digital_min:** Es el valor entero más bajo que puede tomar una muestra digitalizada en este canal, antes de la conversión a unidades físicas. Es un dato cuantitativo discreto (entero). Normalmente está en el rango de -32768 , lo cual corresponde al límite de un entero con signo en 16 bits. Es esencial para la fórmula de conversión.
- **7. digital_max:** Valor entero máximo que puede representar el conversor A/D para este canal. También es cuantitativo discreto. Usualmente es $+32767$ en EEG digitalizado a 16 bits. Junto con `digital_min`, define la escala de digitalización del canal. La relación entre valores físicos y digitales depende directamente de estos dos campos.
- **8. prefiltering:** Campo textual que describe el filtrado previo que se le aplicó a la señal antes de guardarla, como `HP:0.1Hz LP:70Hz`. Es cualitativo nominal u ordinal, dependiendo de si indica frecuencias específicas. Nos ayuda a entender por qué ciertas componentes están ausentes en la señal cruda, como bajas frecuencias filtradas para reducir artefactos.
- **9. samples_per_record:** Indica cuántas muestras hay por cada registro de datos en este canal. Es cuantitativo discreto. Por ejemplo, si cada registro dura 1 segundo y este valor es 256 , entonces el canal tiene una frecuencia de muestreo de 256 Hz. Este campo puede variar entre canales.
- **10. reserved:** Campo reservado sin uso definido, codificado como texto. Es cualitativo nominal y frecuentemente está vacío o contiene texto genérico. Aunque no se usa en la mayoría de los casos, algunos sistemas propietarios podrían emplearlo para codificar metadatos específicos, así que conviene no descartarlo automáticamente.

- **Registros de cada Canal:**

Variable: Muestras digitales por canal (señal cruda): Los datos crudos en un archivo `.edf` son una secuencia continua de muestras digitalizadas, organizadas por registros de datos. Cada muestra representa el valor de la señal en un instante de tiempo para un canal determinado, y está codificada típicamente como un número entero de

16 bits con signo (int16). Estas muestras están intercaladas por canal y ordenadas por bloques (registros), y cada bloque tiene una duración fija especificada en el header (**duration_of_data_record**). Por ejemplo, si tenemos 30 canales y cada registro contiene 256 muestras por canal, cada bloque ocupa 7680 valores (30×256). Esta información es cuantitativa, discreta a nivel de almacenamiento (valores enteros), pero se interpreta como cuantitativa continua una vez que se convierte a unidades físicas como μV . La conversión se realiza mediante una transformación lineal usando los campos **physical_min**, **physical_max**, **digital_min**, y **digital_max** de cada canal.

Tipo de dato: es un **int16** por cada muestra y su tipo general es **uantitativo** con una subcategoría **Discreto**, luego **Continuo** tras conversión física, generalmente entre -32768 y +32767 antes del escalado.

Conversión a unidades físicas: La transformación de cada muestra digital **D** a un valor físico **P** se realiza con:

$$P = \left(\frac{D - D_{min}}{D_{max} - D_{min}} \right) (P_{max} - P_{min}) + P_{min}$$

Donde:

- D = valor digital leído.
- D_{min} , D_{max} = valores mínimos y máximos digitales de cada canal.
- P_{min} , P_{max} valores mínimos y máximos físicos de cada canal.

Tabla 6: Clasificación de los segmentos de señal según tipo de dato.

Variable / Segmento	Tipo de dato	Subcategoría
Muestras digitales (int16)	Cuantitativo	Discreto (almacenado)
Muestras convertidas (microvoltios)	Cuantitativo	Continuo (analizado)

2.3.2. csv file

2.3.3. csv_bi file