

Entorno de Visual Analytics para la limpieza de artefactos en el dataset TUSZ

1 Introducción

El análisis de señales electroencefalográficas (EEG) es fundamental en el estudio de la actividad cerebral y en la detección de eventos clínicamente relevantes como crisis epilépticas [1]. El Database (TUSZ) ofrece un voluminoso conjunto de grabaciones en condiciones reales de monitoreo, lo cual presenta complejidad de las señales en la baja relación señal-ruido, presencia de artefactos musculares, parpadeos y ruido eléctrico.

Por lo tanto estas grabaciones contienen ruido y artefactos (movimientos musculares, parpadeos, latido cardiaco, interferencia eléctrica) [2] que:

- Disminuyen la calidad de la señal útil, elevando el nivel de ruido de fondo.
- Generan transitorios de alta amplitud que pueden confundirse con eventos epilépticos.
- Varían significativamente entre canales y sesiones, complicando la automatización pura.

Esta heterogeneidad y la imposibilidad de procesar múltiples grabaciones de forma fiable pueden conducir a falsos positivos o a la omisión de crisis reales si no se realiza una etapa robusta de detección y limpieza de artefactos previa a cualquier análisis de anomalías.

Así, nuestro objetivo es desarrollar un módulo de preprocesamiento automático que combine técnicas de detección de picos para identificar candidatos a artefactos en cada canal EEG y diseñar un entorno de Visual Analytics que permita inspeccionar de forma interactiva la distribución temporal y espectral de posibles artefactos y agrupar ventanas limpias versus contaminadas para facilitar la revisión.

2 Descripción del objeto de estudio

El **conjunto de datos** utilizado en este trabajo [1] proviene del Temple University Hospital EEG Corpus (TUH EEG Corpus), específicamente de su subcorpus TUH Seizure Corpus (TUSZ), que fue lanzado por primera vez en 2017 y actualizado periódicamente, siendo una de las colecciones públicas más extensas de electroencefalogramas (EEG) clínicos anotados. La versión utilizada en este proyecto es la v2.0.3.

La recolección de datos fue realizada por un equipo multidisciplinario del Laboratorio de Inteligencia Computacional y Bioinformática Médica de la Temple University, en colaboración con médicos neurólogos del hospital universitario. La recolección de los EEG se llevó a cabo en un entorno clínico real, en sesiones de monitoreo rutinario o de emergencia, lo cual proporciona una alta validez ecológica al conjunto de datos. Las señales fueron recolectadas con sistemas de EEG estándar, y las anotaciones de eventos (como crisis epilépticas) fueron realizadas por expertos humanos, con herramientas asistidas por software.

La técnica de recolección fue electroencefalografía multicanal, donde se colocan electrodos en el cuero cabelludo siguiendo el sistema 10-20, y se registran las diferencias de voltaje entre pares de electrodos durante un período de tiempo. Las señales capturadas se almacenaron en archivos en formato EDF (European Data Format), junto con archivos auxiliares .csv y .csv_bi con anotaciones detalladas.

El **objeto de estudio** son las señales eléctricas cerebrales (EEG) registradas desde múltiples canales derivados colocados sobre el cuero cabelludo de pacientes. Estas señales representan la actividad bioeléctrica del cerebro a lo largo del tiempo. La entidad de estudio puede verse también como cada canal derivado en una grabación específica, ya que se analiza su comportamiento para identificar patrones anómalos, como eventos de crisis epilépticas.

¿Cuáles son los atributos que tienen?; ¿Qué significa cada atributo?, entre qué rango están sus valores, ¿qué tipo de dato son? Para ello vamos a dividir esta parte en 3 subsecciones, una para cada tipo de archivo.

2.1 Edf file

Mostraremos una tabla que resume las características de cada variable además describimos lo que significa cada variable, lo hemos dividido en 3 secciones, la primera es la información que nos brinda el header general, el segundo es la información que podemos destacar del header de cada canal y finalmente los datos crudos que son almacenados con la lectura de cada canal.

- **Header General:** Como vemos la tabla 1 la mayoría son de tipo cualitativos sin embargo no hay necesidad de transformarlos a numéricos ya que esta no será con la que trabajaremos directamente. Esta información nos sirve por ejemplo para identificar datos del paciente o datos que corresponden a la lectura de los datos, etc.

Tabla 1: Clasificación de los campos del header general según tipo de dato.

Campo	Tipo	Subcategoría
version	Cualitativo	Nominal (texto)
patient_id	Cualitativo	Nominal (texto)
recording_id	Cualitativo	Nominal (texto)
start_date	Cualitativo	Ordinal (texto de fecha)
start_time	Cualitativo	Ordinal (texto de hora)
header_length	Cuantitativo	Discreto (entero)
reserved	Cualitativo	Nominal (texto libre)
num_records	Cuantitativo	Discreto (entero)
duration_record	Cuantitativo	Continuo (flotante en segundos)
n_signals	Cuantitativo	Discreto (entero)

- **1. version:** Este campo indica la versión del formato EDF que sigue el archivo. Aunque todos los archivos EDF estándar usan simplemente "0" como valor, este campo es útil

para comprobar la conformidad con la especificación del formato y detectar variantes como EDF+ que podrían tener anotaciones adicionales. En resumen, sirve como marca de validación estructural básica del archivo.

- **2. local_patient_id:** Este campo contiene una cadena de texto con información relacionada al paciente, aunque suele estar anonimizada por razones éticas. Puede incluir un identificador interno, edad, sexo o iniciales. Por ejemplo, un valor como "X021 M 29" podría indicar al paciente anónimo X021, masculino, de 29 años. Últimamente este campo generalmente ha sido limpiado para proteger la privacidad.
- **3. local_recording_id:** En este campo se almacena información sobre la grabación específica, como el tipo de estudio, el dispositivo usado, o el montaje del EEG. Por ejemplo, EEG 03_tcp_ar_a indica que se usó el montaje referencial tipo AR-A. Esta información contextualiza el origen y propósito de la grabación, y puede ser útil para segmentar o agrupar archivos por tipo de adquisición.
- **4. start_date:** Representa la fecha en que se inició la grabación del EEG, en el formato texto "dd.mm.yy". Aunque es un texto, se considera un dato ordinal, ya que tiene un orden cronológico natural. Un ejemplo sería "15.03.19", que indica que la grabación comenzó el 15 de marzo de 2019.
- **5. start_time:** Este campo indica la hora exacta en que comenzó la adquisición de datos, en el formato "hh.mm.ss". Al igual que la fecha, también es ordinal. Por ejemplo, "08.45.00" señala que la grabación se inició a las 8:45 a.m.
- **6. header_length:** Indica cuántos bytes ocupa todo el encabezado del archivo EDF, incluyendo el bloque global y los headers de canal. El valor debe ser múltiplo de 256, ya que cada canal adicional agrega 256 bytes. Por ejemplo, un valor de 5120 bytes corresponde a un header global de 256 bytes más 19 canales (19×256). Este valor permite calcular dónde empieza la señal binaria en el archivo.
- **7. reserved:** Campo reservado para usos futuros o personalizados. No tiene una estructura fija y puede estar completamente vacío o contener texto definido por el fabricante o anotaciones específicas del software que generó el archivo. Por ejemplo, en el estándar EDF+ se puede encontrar EDF+C para indicar que el archivo contiene anotaciones clínicas codificadas como canales especiales.
- **8. number_of_data_records:** Este campo indica la cantidad total de registros de datos (o segmentos) en el archivo. Cada uno de estos registros tiene una duración fija especificada en otro campo. Por ejemplo, si el valor es 3600 y cada registro dura 1 segundo, el archivo contiene 1 hora de datos. En variantes como EDF+, un valor de -1 puede usarse para indicar longitud variable o indefinida.
- **9. duration_of_data_record:** Especifica la duración en segundos de cada bloque o registro de datos. Este valor puede ser un número decimal (flotante) como 1.0, 0.5, etc., lo cual determina la resolución temporal del archivo en bloques. Si hay 3600 registros y cada uno dura 1.0 segundo, el total de la grabación es de una hora. Este campo es crucial para reconstruir correctamente el eje temporal de la señal.

- **10. number_of_signals (n_signals):** Este campo indica cuántas señales o canales distintos se registraron en el archivo. En un EEG clínico convencional, este número suele variar entre 19 y 30, incluyendo canales fisiológicos (EEG, ECG, EOG) y posibles canales de anotación. Por ejemplo, un valor de 23 podría indicar 21 canales EEG más 2 de referencia. Esta información es esencial para leer correctamente los headers de canal y la matriz de datos.

- **Header de cada Canal:** Vamos ahora con los headers de cada canal en un archivo .edf, que vienen justo después del header global. Como sabemos, cada canal aporta 256 bytes, y hay *n_signals* canales (según el campo del header global).

Tabla 2: Clasificación de los campos del header por canal según tipo de dato.

Campo / Variable	Tipo de dato	Subcategoría
label	Cualitativo	Nominal (texto)
transducer_type	Cualitativo	Nominal (texto)
physical_dim	Cualitativo	Nominal (texto)
physical_min	Cuantitativo	Continuo (flotante)
physical_max	Cuantitativo	Continuo (flotante)
digital_min	Cuantitativo	Discreto (entero)
digital_max	Cuantitativo	Discreto (entero)
prefiltering	Cualitativo	Nominal u ordinal (texto estructurado) ^a
samples_per_record	Cuantitativo	Discreto (entero)
reserved	Cualitativo	Nominal (texto libre)

^a Puede incluir orden en las configuraciones de filtros: HP, LP, Notch, etc.

A continuación mostramos la descripción de cada variable:

- **1. label:** Este campo es una cadena de texto que identifica el nombre del canal o señal. Por ejemplo, EEG FP1-REF o ECG. Es un dato cualitativo nominal, ya que nombra la fuente de la señal sin ningún orden inherente. Es fundamental para saber qué tipo de actividad se está midiendo y para alinear canales entre diferentes grabaciones o estándares de montaje.
- **2. transducer_type:** Este campo describe el tipo de transductor o electrodo utilizado para captar la señal, como AgCl electrode, surface o depth. También es un dato cualitativo nominal. Aunque a menudo se deja vacío o se rellena de forma genérica, es útil para distinguir entre técnicas de adquisición distintas.
- **3. physical_dimension:** Indica la unidad física de la señal grabada, como μV (microvoltios), mV, Ohm, etc. Se trata de un dato cualitativo nominal. Este campo es clave para interpretar correctamente el valor físico de cada muestra y evitar errores al comparar señales de diferentes canales o archivos. En EEG, lo habitual es encontrar μV .
- **4. physical_min:** Este campo especifica el valor físico mínimo que puede representar el canal tras el escalado desde

valores digitales. Es un dato cuantitativo continuo, usualmente en flotante. Por ejemplo, un canal podría tener -500.0 μV como mínimo físico. Junto con `physical_max`, define el rango de voltajes reales captados.

- **5. `physical_max`:** Complementario al anterior, este campo indica el valor físico máximo representable tras el escalado. También es cuantitativo continuo. Por ejemplo, si el canal va de -500.0 a +500.0 μV , este campo tendrá 500.0. Estos dos extremos permiten mapear los datos digitales a sus valores reales físicos.
- **6. `digital_min`:** Es el valor entero más bajo que puede tomar una muestra digitalizada en este canal, antes de la conversión a unidades físicas. Es un dato cuantitativo discreto (entero). Normalmente está en el rango de -32768, lo cual corresponde al límite de un entero con signo en 16 bits. Es esencial para la fórmula de conversión.
- **7. `digital_max`:** Valor entero máximo que puede representar el conversor A/D para este canal. También es cuantitativo discreto. Usualmente es +32767 en EEG digitalizado a 16 bits. Junto con `digital_min`, define la escala de digitalización del canal. La relación entre valores físicos y digitales depende directamente de estos dos campos.
- **8. `prefiltering`:** Campo textual que describe el filtrado previo que se le aplicó a la señal antes de guardarla, como HP:0.1Hz LP:70Hz. Es cualitativo nominal u ordinal, dependiendo de si indica frecuencias específicas. Nos ayuda a entender por qué ciertas componentes están ausentes en la señal cruda, como bajas frecuencias filtradas para reducir artefactos.
- **9. `samples_per_record`:** Indica cuántas muestras hay por cada registro de datos en este canal. Es cuantitativo discreto. Por ejemplo, si cada registro dura 1 segundo y este valor es 256, entonces el canal tiene una frecuencia de muestreo de 256 Hz. Este campo puede variar entre canales.
- **10. `reserved`:** Campo reservado sin uso definido, codificado como texto. Es cualitativo nominal y frecuentemente está vacío o contiene texto genérico. Aunque no se usa en la mayoría de los casos, algunos sistemas propietarios podrían emplearlo para codificar metadatos específicos, así que conviene no descartarlo automáticamente.

• Registros de cada Canal:

Variable: Muestras digitales por canal (señal cruda): Los datos crudos en un archivo .edf son una secuencia continua de muestras digitalizadas, organizadas por registros de datos. Cada muestra representa el valor de la señal en un instante de tiempo para un canal determinado, y está codificada típicamente como un número entero de 16 bits con signo (int16). Estas muestras están intercaladas por canal y ordenadas por bloques (registros), y cada bloque tiene una duración fija especificada en el header (`duration_of_data_record`). Por ejemplo, si tenemos 30 canales y cada registro contiene 256 muestras por canal, cada bloque ocupa 7680 valores (30×256). Esta información es cuantitativa, discreta a nivel de almacenamiento (valores enteros), pero se interpreta como cuantitativa continua una vez que se convierte a unidades físicas como μV . La conversión se realiza mediante una transformación lineal usando los campos `physical_min`, `physical_max`, `digital_min`,

y `digital_max` de cada canal.

Tipo de dato: es un int16 por cada muestra y su tipo general es uantitativo con una subcategoría Discreto, luego Continuo tras conversión física, generalmente entre -32768 y +32767 antes del escalado.

Conversión a unidades físicas: La transformación de cada muestra digital D a un valor físico P se realiza con:

$$P = \left(\frac{D - D_{min}}{D_{max} - D_{min}} \right) (P_{max} - P_{min}) + P_{min}$$

Donde:

- D = valor digital leído.
- D_{min}, D_{max} = valores mínimos y máximos digitales de cada canal.
- P_{min}, P_{max} = valores mínimos y máximos físicos de cada canal.

Tabla 3: Clasificación de los segmentos de señal según tipo de dato.

Variable	Tipo	Subcategoría
Muestras digitales (int16)	Cuantitativo	Discreto (almacenado)
Muestras convertidas (microvoltios)	Cuantitativo	Continuo (analizado)

2.2 csv file

Como sabemos el .csv va a contener las anotaciones de ciertos intervalos indicando el tipo de seizure:

Tabla 4: Clasificación de las variables presentes en los archivos .csv (event-based, multiclase).

Campo	Tipo de dato	Subcategoría
channel	Cualitativo	Nominal (texto)
start_time	Cuantitativo	Continuo (flotante en segundos)
stop_time	Cuantitativo	Continuo (flotante en segundos)
label	Cualitativo	Nominal (clase multiclase)
confidence	Cuantitativo	Continuo (probabilidad)

A continuación mostramos la descripción de cada variable:

- **channel:** Esta variable cualitativa de tipo nominal indica el nombre del canal EEG en el que se ha detectado un evento. Los canales representan derivaciones específicas entre dos electrodos, por ejemplo, FP1-F7, lo cual indica que la señal se obtuvo entre los electrodos FP1 y F7. No hay un orden inherente entre los distintos nombres, ya que corresponden a configuraciones anatómicas específicas del montaje EEG.
- **start_time:** Corresponde al tiempo en segundos en el que inicia el evento anotado en el canal especificado. Es una variable cuantitativa continua representada como número decimal, lo que permite ubicar con precisión el inicio de la actividad de interés dentro del registro EEG.

- **stop_time:** Indica el tiempo en segundos en el que finaliza el evento anotado. Al igual que start_time, es una variable cuantitativa continua. El rango entre start_time y stop_time define la duración total del evento observado en el canal.
- **label:** Esta variable cualitativa de tipo nominal representa la clase del evento EEG identificado. Puede tomar valores como NULL, SPSW, GPED, PLED, EYBL, ARTF, BCKG, SEIZ, FNSZ, GNSZ, SPSZ, CPSZ, ABSZ, TNSZ, CNSZ, TCSZ, ATSZ, MYSZ, NESZ, INTR, SLOW, EYEM, CHEW, SHIV, MUSC, ELPP, ELST, CALB, HPHS, TRIP. Estas etiquetas son esenciales para la clasificación y análisis de patrones EEG.
- **confidence:** Se refiere al grado de certeza o probabilidad asignada al evento detectado, normalmente expresada como un valor entre 0 y 1. Esta variable cuantitativa continua ayuda a evaluar la fiabilidad de la anotación. Un valor de 1.0000 indica máxima confianza en la etiqueta asignada.

2.3 csv_bi file

[evisar russel] El archivo .csv_bi contiene una representación event-based y multiclase de las anotaciones realizadas sobre un archivo EEG. Para cada canal derivado, detalla intervalos temporales asociados a distintos tipos de eventos (por ejemplo, fondo, crisis, artefactos), junto con una etiqueta categórica y un nivel de confianza en dicha anotación. Este archivo permite identificar y segmentar la señal EEG en fragmentos relevantes para el análisis clínico o computacional, facilitando el entrenamiento o la evaluación de modelos que trabajan con información canalizada y etiquetada. A diferencia de anotaciones binarias globales, esta estructura permite una resolución precisa por canal, lo cual es clave en estudios de localización de actividad cerebral o de patrones específicos en distintas regiones.

Campo	Tipo	Subcategoría
channel	Cualitativo	Nominal (texto)
start_time	Cuantitativo	Continuo (float)
stop_time	Cuantitativo	Continuo (float)
label	Cualitativo	Nominal (texto)
confidence	Cuantitativo	Continuo (float) (probabilidad)

- **channel:** Este campo no indica el nombre de un canal EEG derivado sino TERM que hace referencia a todos los canales. Es un dato cualitativo de tipo nominal, ya que su valor no tienen un orden inherente.
- **start_time:** Representa el instante en el que comienza la anotación del evento, medido en segundos desde el inicio del registro EEG. Es un dato cuantitativo continuo, expresado como un número decimal (float), lo cual permite una localización precisa dentro de la señal.
- **stop_time:** Similar a start_time, este campo indica el tiempo de finalización del evento en segundos. También es un dato cuantitativo continuo (float). La duración del evento puede calcularse como la diferencia entre stop_time y start_time.
- **label:** Contiene la clase del evento identificado en la señal EEG. Por ejemplo: bckg (actividad de fondo), seiz (crisis) solo esos dos. Es un dato cualitativo de tipo nominal, ya que los valores son categorías sin un orden jerárquico.
- **confidence:** Este campo numérico (float) expresa el grado de certeza con el que se ha asignado la etiqueta correspondiente. Es una medida de probabilidad, típicamente entre 0.0 y 1.0. Valores cercanos a 1 indican alta confianza en la anotación.

Referencias

- [1] Shah, V., Von Weltin, E., Lopez, S., McHugh, J. R., Veloso, L., Golmohammadi, M., Obeid, I., y Picone, J., "The temple university hospital seizure detection corpus", Frontiers in neuroinformatics, vol. 12, p. 83, 2018.
- [2] Chaddad, A., Wu, Y., Kateb, R., y Bouridane, A., "Electroencephalography signal processing: A comprehensive review and analysis of methods and techniques", Sensors, vol. 23, no. 14, p. 6434, 2023.