

Pipeline Ciencia de Datos

Conjunto de datos TUSZ

Integrantes: Jorge Tito Ccahuaya
Profesor: Ana Maria Cuadros Valdivia
Fecha de realización: 6 de junio de 2025
Fecha de entrega: 6 de junio de 2025
Arequipa - Perú

Índice de Contenidos

1. Introducción	1
2. ¿ Qué problemas se identifican ?	1
2.1. Anotaciones de eventos seizure con duración anómalamente extensa que no reflejan crisis clínicas reales.	1
2.2. Variabilidad en la participación de canales derivados en eventos de seizure .	2
3. ¿Qué se descubrió al analizar los datos?	3
3.1. Inexistencia de montajes para la configuracion 02_tcp_le	4
3.2. Alta variabilidad en la duración total de eventos epilépticos entre pacientes	6
4. Cómo se ve afectado el comportamiento en relación con la geografía	7

Índice de Figuras

1. Time Anomalo del paciente aaaaakkm	1
2. Señales asociado al timeline 1	2
3. Heatmap de actividad seiz por canal EEG y paciente	3
4. Configuración en train	5
5. Configuración en dev	5
6. Configuración en eval	6
7. Variabilidad en la duracion de eventos epilépticos entre pacientes	7
8. Mapa De Calor EEG Suavizado Por Canal Derivado	8

Índice de Tablas

1. Montajes bipolares utilizados: canal derivado y sus electrodos referenciales. . .	4
--	---

1. Introducción

En este informe se presenta los resultados del pipeline de Ciencia de Datos que se hacen sobre el dataset **TUSZ**. El objetivo es encontrar problemas que se pueden encontrar en el dataset, además de mencionar, luego que descubrimos al analizar los datos y [3] y [4], cabe recalcar que los pasos o etapas del pipeline de ciencia de datos ya han sido abordado y por lo tanto una vez que hayamos hecho ello podemos recién ver los problema que tuvimos.

2. ¿ Qué problemas se identifican ?

2.1. Anotaciones de eventos seizure con duración anómalamente extensa que no reflejan crisis clínicas reales.

Haciendo un análisis por paciente pudimos encontrarnos que para el paciente **aaaaakkm** en una de la sesiones tomadas, el tiempo que presentó un evento epiléptico es de casi 40 minutos, entonces consideramos que dicha anotaciones tiene una duración anómalamente extensa que no reflejan crisis clínicas reales ya que la mayoría de las crisis epilépticas generalizadas duran entre 30 segundos y 2 minutos y se considera una emergencia médica cuando la duración supera los 5 minutos a esto se llama estatus epiléptico (status epilepticus), y requiere intervención médica urgente. <https://www.epilepsy.com>

A continuación mostramos el timeLine del paciente comparado con uno normal.




Figura 1: Time Anomalo del paciente **aaaaakkm**




Figura 2: Señales asociado al timeline 1

Este hallazgo cuestiona la fiabilidad del archivo de etiquetas. Afecta directamente tareas de detección automática y evaluación clínica. Además, ilustra cómo la validación cruzada entre .edf y .csv_bi es crucial. Sin embargo no se descarta como un evento normal ya que como atributo de confianza que mide la confiabilidad sobre dicha anotación es de 1, es decir que se tiene que confiar al 100 %.

2.2. Variabilidad en la participación de canales derivados en eventos de seizure

Durante los eventos epilépticos registrados en el dataset TUSZ, se espera que múltiples canales derivados participen de manera simultánea o coherente, dado que las crisis suelen propagarse entre regiones cerebrales conectadas. Sin embargo, al analizar la información cruzada entre los archivos .csv y los pacientes, se observa una alta variabilidad en los canales involucrados en los eventos etiquetados como seiz o algún tipo de seiz.

Esta falta de regularidad puede representar un problema tanto para la interpretación clínica como para el diseño de modelos automáticos de detección, ya que algunos canales aparecen recurrentemente durante las crisis, mientras que otros rara vez están activos. La participación de canales varía mucho de un paciente a otro, lo que sugiere patrones individuales o inconsistencias en la anotación.




Figura 3: Heatmap de actividad seiz por canal EEG y paciente

La imagen corresponde a una matriz de calor (heatmap) construida a partir de una muestra de datos EEG. En esta visualización se analizaron 25 pacientes distintos. Se consideraron 30 canales derivados de EEG. Cada celda de la matriz representa la frecuencia de eventos seizure detectados en un canal específico para un paciente determinado.

En la figura 3 se observa una alta heterogeneidad horizontal y vertical, lo que indica que algunos canales presentan activación frecuente (zonas más rojas) a lo largo de múltiples pacientes. Otros canales tienen participación esporádica o nula. No todos los pacientes presentan actividad intensa en los mismos canales, lo que refleja la variabilidad interindividual en la manifestación de las crisis epilépticas. Esta diversidad en patrones sugiere que no todos los canales aportan información relevante en todos los casos.

3. ¿Qué se descubrió al analizar los datos?

3.1. Inexistencia de montajes para la configuracion 02_tcp_le

Actualmente existen dos tipos de configuraciones principales, el 01_tcp_ar y el 02_tcp_le, el primero es una diferencia entre el electrodo principal con la media de los restantes, y el segundo en la diferencia entre el principal y el promedio de los canale A1 y A2 que estn ubicados en los extremos de los oidos. En la documentación del dataset nos proporciona los montajes para la configuración 01_tcp_ar Tabla(1)

Tabla 1: Montajes bipolares utilizados: canal derivado y sus electrodos referenciales.

#	Canal derivado	Electrodo A	Electrodo B
0	FP1-F7	EEG FP1-REF	EEG F7-REF
1	F7-T3	EEG F7-REF	EEG T3-REF
2	T3-T5	EEG T3-REF	EEG T5-REF
3	T5-O1	EEG T5-REF	EEG O1-REF
4	FP2-F8	EEG FP2-REF	EEG F8-REF
5	F8-T4	EEG F8-REF	EEG T4-REF
6	T4-T6	EEG T4-REF	EEG T6-REF
7	T6-O2	EEG T6-REF	EEG O2-REF
8	A1-T3	EEG A1-REF	EEG T3-REF
9	T3-C3	EEG T3-REF	EEG C3-REF
10	C3-CZ	EEG C3-REF	EEG CZ-REF
11	CZ-C4	EEG CZ-REF	EEG C4-REF
12	C4-T4	EEG C4-REF	EEG T4-REF
13	T4-A2	EEG T4-REF	EEG A2-REF
14	FP1-F3	EEG FP1-REF	EEG F3-REF
15	F3-C3	EEG F3-REF	EEG C3-REF
16	C3-P3	EEG C3-REF	EEG P3-REF
17	P3-O1	EEG P3-REF	EEG O1-REF
18	FP2-F4	EEG FP2-REF	EEG F4-REF
19	F4-C4	EEG F4-REF	EEG C4-REF
20	C4-P4	EEG C4-REF	EEG P4-REF
21	P4-O2	EEG P4-REF	EEG O2-REF

Sin embargo no nos proporcionan un montaje para la configuracion 02_tcp_le lo cuál es un problema ya que al momento de hacer la diferencia entre canales para hacer los montajes respectivos no tenemos una tabla de comparación, a pesar de que la configuracion 02_tcp_le representa una proporción menor que la configuración 01_tcp_ar ésta es primordial ya que se

estaría omitiendo gran parte de información si es que no lo consideramos en análisis futuros.




Figura 4: Configuración en train




Figura 5: Configuración en dev



Figura 6: Configuración en eval

En las Figuras 4, 5 y 6 mostramos las proporciones de 02_tcp_le con 01_tcp_ar

3.2. Alta variabilidad en la duración total de eventos epilépticos entre pacientes

Durante el análisis exploratorio del conjunto de datos EEG del corpus TUSZ, se observó una alta variabilidad en la duración total de los eventos etiquetados como seizure por paciente. Para cuantificar este fenómeno, se procesaron los archivos de anotaciones (.csv_bi) asociados a cada señal EEG (.edf) dentro de la partición analizada, extrayendo los intervalos marcados como seiz y acumulando su duración por paciente.

El resultado se representó mediante un gráfico de barras, donde cada barra muestra el tiempo total (en segundos) que un paciente ha estado en estado de crisis epiléptica durante sus grabaciones.

Interpretación del gráfico: Algunos pacientes acumulan solo unos minutos de actividad seiz, mientras que otros superan los cientos de minutos, lo que indica una fuerte dispersión en la severidad, frecuencia o duración de las crisis. En ciertos casos, se identificaron valores atípicos inusualmente altos, los cuales podrían corresponder a episodios clínicamente complejos (por ejemplo, status epiléptico) o errores de anotación, donde intervalos excesivamente largos fueron etiquetados como seiz sin interrupción, aunque este último se descarta porque la mayoría de archivo tiene como confianza el 100 %. Esta variabilidad complica el entrenamiento de modelos automáticos, ya que introduce un sesgo de duración si no se normaliza o analiza correctamente.




Figura 7: Variabilidad en la duracion de eventos epilépticos entre pacientes

4. Cómo se ve afectado el comportamiento en relación con la geografía

En el contexto del presente análisis, la variable geografía no corresponde a una ubicación geoespacial externa, sino a una distribución espacial dentro del cuero cabelludo humano, es decir la ubicación de los canales. Dado que las señales EEG se registran mediante canales derivados ubicados según el sistema 10–20 internacional, se puede considerar que cada canal representa una región funcional o anatómica del cerebro.

Con esta interpretación, se elaboró una visualización que representa un mapa de calor proyectado sobre una silueta del cráneo, donde cada canal derivado indica su frecuencia total de participación en eventos epilépticos (seizure), calculada a partir de las anotaciones presentes en los archivos `.csv_bi`.

En la figura (8) se muestra una interpolación suave (cubic) de las frecuencias de crisis detectadas por canal. Cada punto negro representa un canal derivado típico del dataset TUSZ (como, FP1-F7, F7-T3, T3-T5, etc.). Los colores van desde tonos claros (baja frecuencia) hasta rojo intenso (alta frecuencia de eventos seizure).

Mapa de calor EEG suavizado por canal derivado (estilo TUSZ)




Figura 8: Mapa De Calor EEG Suavizado Por Canal Derivado

Entonces se identifican zonas de mayor participación en las crisis epilépticas, principalmente en regiones temporales y frontales (canales como F7-T3, FP1-F7, F8-T4, etc.).

Zonas posteriores y centrales presentan menor actividad, lo que sugiere que el foco epiléptico en muchos pacientes está localizado en zonas anteriores del cerebro.

La distribución espacial de los eventos seizure no es uniforme. Existen zonas anatómicas más activas que otras, lo cual refleja que el comportamiento epiléptico se ve afectado por la ubicación de los electrodos en el cuero cabelludo.