

DEAP Dataset

Data Wrangling - Análisis Exploratorio de Datos

Integrantes: Jorge Tito Ccahuaya
Profesor: Ana Maria Cuadros Valdivia
Fecha de realización: 22 de mayo de 2026
Fecha de entrega: 22 de mayo de 2026
Arequipa - Perú

Índice de Contenidos

1. Metadata	1
1.1. Descripción general	1
1.2. Origen y objetivo del dataset	1
1.3. Contexto experimental	1
1.4. Participantes y adquisición	1
1.5. Modalidades registradas	1
1.6. Estructura de los trials	2
1.7. Escalas emocionales utilizadas	2
1.8. Aplicaciones y usos del dataset	2
2. Estructura Interna de un archivo .bdf	3
2.1. Header Fijo	3
2.2. Header por canal	3
2.3. Data Record	4
3. Comportamiento de los datos	5
3.1. Señales Fisiológicas (.bdf file)	5
3.1.1. ¿Qué representa un registro?	6
3.1.2. ¿Cuántos registros hay ?	7
3.1.3. ¿Qué datos son discretos y cuáles continuos?	9
3.1.4. ¿Están todas las filas completas o tenemos campos con valores nulos?	10
3.2. Online_ratings (.csv file)	11
3.2.1. ¿Qué representa un registro?	12
3.2.2. ¿Cuántos registros hay ?	12
3.2.3. ¿Siguen alguna distribución?	12
3.2.4. ¿Hay correlación entre features (características)?	15
3.3. Participant_ratings (.csv file)	15
3.3.1. ¿Qué representa un registro?	16
3.3.2. ¿Cuántos registros hay ?	16
3.3.3. ¿Siguen alguna distribución?	16
3.3.4. ¿Existe alguna correlación enter features?	20
3.4. Participant_questionnaire (.csv file)	20
3.4.1. ¿Qué representa un registro?	21
3.5. Video_list (.csv file)	21
3.5.1. ¿Qué representa un registro?	22
4. Hipótesis	23
4.1. Hipótesis 1	23
4.2. Hipótesis 2	24
4.3. Hipótesis 3	25
Referencias	25

Índice de Figuras

1. Imágenes usadas para la autoevaluación. Valence SAM, arousal SAM, dominance SAM, and liking [1]	2
2. Estructura general de un archivo .bdf	3
3. Estructura del Data Record del archivo .bdf	4
4. Sistema internacional de EEG 10-20 con 32 electrodos.	5

5.	Ubicación de los canales restantes	6
6.	Rueda emocional utilizada para representar relaciones de similitud entre distintos estados emocionales, organizada según dimensiones de valencia y control emocional.[2]	11
7.	Distribución de la variable Valence	13
8.	Distribución de la variable Arousal	14
9.	Distribución de la variable Dominance	14
10.	Matriz de correlación de las calificaciones online	15
11.	Distribución de la variable Valence	17
12.	Distribución de la variable Arousal	18
13.	Distribución de la variable Dominance	18
14.	Distribución de la variable Liking	19
15.	Distribución de la variable Familiarity	19
16.	Correlación entre variables emocionales	20
17.	Dashboard Hipótesis 1	23
18.	Dashboard Hipótesis 2	24
19.	Dashboard Hipótesis 3	25

Índice de Tablas

1.	Estructura del header fijo en archivos BDF	3
2.	Estructura del header por canal en archivos BDF	4
3.	Resumen general de archivos principales del dataset DEAP	5
4.	Descripción de canales contenidos en los archivos BDF del dataset DEAP	6
5.	Valores de samples per record de cada canal por participante del dataset DEAP.	7
6.	Resumen de duración, tamaño estimado y memoria requerida por participante del dataset DEAP.	8
7.	Resumen de canales y propiedades técnicas del dataset DEAP	9
8.	Resumen de cantidad de canales y valores nulos por participante del dataset DEAP.	10
9.	Descripción de columnas del archivo online ratings	12
10.	Resumen estructural del dataframe <code>online_ratings</code>	12
11.	Estadísticas descriptivas del dataframe <code>online_ratings</code>	13
12.	Descripción de columnas del archivo participant ratings	16
13.	Resumen estructural del dataframe <code>participant_ratings</code>	16
14.	Estadísticas descriptivas del dataframe <code>participant_ratings</code>	17
15.	Descripción de columnas del archivo participant questionnaire	21
16.	Descripción de columnas del archivo video list	22

1. Metadata

1.1. Descripción general

DEAP (Database for Emotion Analysis using Physiological Signals) es un dataset multimodal diseñado para el análisis de emociones humanas a partir de señales fisiológicas y estímulos audiovisuales. El dataset contiene registros EEG, señales periféricas y evaluaciones subjetivas obtenidas durante la exposición de participantes a fragmentos de videos musicales con contenido emocional. El objetivo principal del dataset es facilitar investigaciones relacionadas con reconocimiento de emociones, affective computing y análisis de señales fisiológicas multicanal.

1.2. Origen y objetivo del dataset

El dataset DEAP fue desarrollado por investigadores de Queen Mary University of London, University of Twente y University of Geneva como parte de investigaciones orientadas al análisis automático de emociones humanas mediante señales fisiológicas. Para construir el dataset, inicialmente se seleccionaron 120 videos musicales candidatos utilizando etiquetas afectivas provenientes de Last.fm y selección manual. Posteriormente, dichos videos fueron evaluados por voluntarios mediante anotaciones subjetivas de valencia y arousal, seleccionándose finalmente 40 estímulos con respuestas emocionales más consistentes.

1.3. Contexto experimental

El experimento fue realizado en un entorno controlado de laboratorio. Cada participante observó 40 fragmentos de videos musicales mientras se registraban señales EEG y señales fisiológicas periféricas. Durante cada trial se siguió un protocolo compuesto por un periodo de baseline, la reproducción del estímulo audiovisual y una etapa posterior de autoevaluación emocional mediante escalas subjetivas.

1.4. Participantes y adquisición

El dataset fue registrado utilizando 32 participantes. Las señales EEG fueron adquiridas mediante 32 canales con una frecuencia de muestreo de 512 Hz, además de múltiples señales fisiológicas periféricas. Los datos fueron almacenados en archivos fisiológicos junto con metadata relacionada con los participantes y las evaluaciones subjetivas obtenidas durante el experimento.

1.5. Modalidades registradas

DEAP es considerado un dataset multimodal debido a que integra múltiples tipos de información cerebral y fisiológica. Entre las modalidades registradas se incluyen:

- Señales EEG (32 canales)
- Señales EOG (2 canales)
- Señales EMG (x canales)
- Respiración
- Temperatura
- Respuesta galvánica de la piel
- Estímulos audiovisuales

Además de los 32 archivos .bdf donde se almacenan todas las señales EXG, el dataset incluye metadata asociada a los estímulos utilizados y a las respuestas proporcionadas por los participantes en **Online_ratings.csv**, **Video_list.csv**, **Participant_ratings.csv** y **Participant_questionnaire.csv**.

1.6. Estructura de los trials

Cada participante fue expuesto a 40 trials experimentales. En cada trial se presentó un estímulo audiovisual acompañado de un protocolo temporal compuesto por distintas etapas experimentales. Durante el análisis del canal ‘Status’ de los archivos .bdf, se identificaron eventos repetitivos asociados al inicio del baseline, inicio del estímulo emocional y finalización del estímulo, permitiendo relacionar temporalmente los registros fisiológicos con cada trial experimental.

1.7. Escalas emocionales utilizadas

Después de cada trial, los participantes realizaron una evaluación subjetiva de sus emociones utilizando escalas tipo SAM (Self-Assessment Manikin).

Las dimensiones emocionales registradas incluyen:

- Valence
- Arousal
- Dominance
- Liking,
- Familiarity.




Figura 1: Imágenes usadas para la autoevaluación. Valence SAM, arousal SAM, dominance SAM, and liking [1]

Estas evaluaciones fueron almacenadas en los archivos de metadata asociados al dataset.

1.8. Aplicaciones y usos del dataset

El dataset DEAP ha sido ampliamente utilizado en investigaciones relacionadas con:

- Reconocimiento de emociones

- Affective computing
- Clasificación emocional
- Análisis de señales EEG, análisis de señales fisiológicas
- Aprendizaje multimodal

Debido a su naturaleza multimodal y temporal, DEAP también es utilizado como benchmark en tareas de machine learning y análisis exploratorio de datos fisiológicos.

2. Estructura Interna de un archivo .bdf

Podemos dividir la estructura de un archivo .bdf en tres partes principales de manera continua: el header fijo que consta de 256 bytes, el header por canal que consta de 256 x N bytes, siendo N el número de canales registrados, y finalmente los datos de las señales EXG que se almacenane en formato binario. En la figura 2 se muestra un esquema general.




Figura 2: Estructura general de un archivo .bdf

A continuación se describen el contenido de cada una de estas partes:

2.1. Header Fijo

La Tabla 1 presenta la estructura general del header fijo de los archivos BDF, el cual almacena información global de la grabación, como identificación del participante, fecha de adquisición, cantidad de canales y configuración general de los data records. Esta sección ocupa los primeros 256 bytes del archivo y permite interpretar correctamente el resto de la estructura binaria.

Tabla 1: Estructura del header fijo en archivos BDF

#	Campo	len (bytes)	Posición (bytes)	Descripción
1	Version	8	0–7	Versión del formato BDF
2	Patient ID	80	8–87	Identificador participante
3	Recording ID	80	88–167	Información grabación
4	Start Date	8	168–175	Fecha de inicio de la grabación (dd.mm.yy)
5	Start Time	8	176–183	Hora de inicio de la grabación (hh.mm.ss)
6	Header Bytes	8	184–191	Total de bytes del header (256 + 256 * N)
7	Reserved	44	192–235	Campo reservado (relleno con espacios)
8	Number of Data Records	8	236–243	Cantidad total de data records (R)
9	Duration of a Data Record	8	244–251	Duración de cada data record en segundos
10	Number of Channels (N)	4	252–255	Número total de canales registrados

2.2. Header por canal

La Tabla 2 resume la estructura del header específico por canal en los archivos BDF, donde se almacenan las propiedades técnicas asociadas a cada señal registrada, incluyendo unidades físicas, rangos digitales y físicos, filtros aplicados y cantidad de muestras por data record.

Tabla 2: Estructura del header por canal en archivos BDF

Orden	Campo	len por canal (bytes)	Total sección (N canales)	Descripción
1	Label	16	$16 \times N$	Nombre del canal
2	Transducer Type	80	$80 \times N$	Tipo de transductor
3	Physical Dimension	8	$8 \times N$	Unidad física
4	Physical Minimum	8	$8 \times N$	Valor mínimo físico
5	Physical Maximum	8	$8 \times N$	Valor máximo físico
6	Digital Minimum	8	$8 \times N$	Valor mínimo digital (típicamente -8388608)
7	Digital Maximum	8	$8 \times N$	Valor máximo digital (típicamente 8388607)
8	Prefiltering	80	$80 \times N$	Información de filtros analógicos aplicados
9	Samples per Data Record	8	$8 \times N$	Número de muestras en cada data record
10	Reserved	32	$32 \times N$	Campo reservado (relleno con espacios)

2.3. Data Record

Posterior al header fijo y al header por canal, sigue los data records ubicados secuencialmente, ello se muestra en la figura 3.




Figura 3: Estructura del Data Record del archivo .bdf

3. Comportamiento de los datos

El Dataset DEAP contiene archivos mostrados en la tabla 3.

Tabla 3: Resumen general de archivos principales del dataset DEAP

File name	Format	Contents
Online_ratings	xls, csv, ods spreadsheet	Todas las evaluaciones individuales recopiladas durante la autoevaluación en línea.
Video_list	xls, csv, ods spreadsheet	Información de videos musicales utilizados en la autoevaluación y el experimento, incluyendo estadísticas emocionales derivadas de las evaluaciones.
Participant_ratings	xls, csv, ods spreadsheet	Evaluaciones emocionales realizadas por los participantes durante el experimento.
Participant_question	xls, csv, ods spreadsheet	Respuestas del cuestionario completado por los participantes antes del experimento.
Face_video	Zip file	Grabaciones de video facial frontal correspondientes a los participantes 1–22.
Data_original	Zip file	Registros fisiológicos originales sin procesar en formato BioSemi .bdf.
Data_preprocessed	Zip file for Python and Matlab	Registros fisiológicos preprocesados, incluyendo filtrado, downsampling y segmentación, en formatos compatibles con Python y Matlab.

3.1. Señales Fisiológicas (.bdf file)




Figura 4: Sistema internacional de EEG 10-20 con 32 electrodos.




Figura 5: Ubicación de los canales restantes

Los archivos `.bdf` del dataset DEAP contienen señales multicanal sincronizadas registradas durante la exposición de los participantes a estímulos emocionales audiovisuales. Estas señales incluyen actividad cerebral cortical (EEG), señales auxiliares asociadas a movimientos oculares y actividad muscular (EXG), señales fisiológicas periféricas y un canal de eventos experimentales (**Status**). La Tabla 4 presenta una descripción general de los distintos grupos de señales contenidos en cada archivo `.bdf`.

Tabla 4: Descripción de canales contenidos en los archivos BDF del dataset DEAP

Channel number	Channel name	Channel content
1–32	Fp1, ...	Estos canales capturan la actividad neuronal de las regiones cerebrales frontal, temporal, central, parietal y occipital.
33	EXG1	hEOG ₁ (to the left of left eye)
34	EXG2	hEOG ₂ (to the right of right eye)
35	EXG3	vEOG ₁ (above right eye)
36	EXG4	vEOG ₄ (below right eye)
37	EXG5	zEMG ₁ (Zygomaticus Major, +/- 1cm from left corner of mouth)
38	EXG6	zEMG ₂ (Zygomaticus Major, +/- 1cm from zEMG ₁)
39	EXG7	tEMG ₁ (Trapezius, left shoulder blade)
40	EXG8	tEMG ₂ (Trapezius, +/- 1cm below tEMG ₁)
41	GSR1	Galvanic skin response, left middle and ring finger
42	GSR2	Unused
43	Erg1	Unused
44	Erg2	Unused
45	Resp	Respiration belt
46	Plet	Plethysmograph, left thumb
47	Temp	Temperature, left pinky
48	Status	Status channel containing markers

3.1.1. ¿Qué representa un registro?

Cada registro temporal representa una muestra sincronizada de todas las señales multicanal en un instante de tiempo t_i , incluyendo actividad EEG cortical, señales fisiológicas periféricas y marcas experimentales del canal **Status**.

3.1.2. ¿Cuántos registros hay ?

Antes de poder responder a esta pregunta, es necesario saber cual es la frecuencia de muestreo de cada canal para poder determinar el número de registros totales, eso para cada participante. Para esto se realizó una lectura del atributo samples per record de todos los canales de los archivos .bdf leyendo el valor en la posición correspondiente tanto del header fijo como del header por cada canal. El resultado se muestra en la tabla 5.

Tabla 5: Valores de samples per record de cada canal por participante del dataset DEAP.

Participant	Channels	Record duration	Num. records	Samples/record
s01	48	1.0	3869	[512]
s02	48	1.0	3703	[512]
s03	48	1.0	3885	[512]
s04	48	1.0	3301	[512]
s05	48	1.0	3916	[512]
s06	48	1.0	3586	[512]
s07	48	1.0	3571	[512]
s08	48	1.0	3517	[512]
s09	48	1.0	3767	[512]
s10	48	1.0	3512	[512]
s11	48	1.0	4161	[512]
s12	48	1.0	3498	[512]
s13	48	1.0	3711	[512]
s14	48	1.0	3937	[512]
s15	48	1.0	4072	[512]
s16	48	1.0	3683	[512]
s17	48	1.0	3446	[512]
s18	48	1.0	3628	[512]
s19	48	1.0	3746	[512]
s20	48	1.0	3509	[512]
s21	48	1.0	3551	[512]
s22	48	1.0	3719	[512]
s23	48	1.0	3601	[512]
s24	48	1.0	4712	[512]
s25	48	1.0	4120	[512]
s26	48	1.0	3913	[512]
s27	48	1.0	3798	[512]
s28	48	1.0	3527	[512]
s29	49	1.0	3978	[512]
s30	49	1.0	3665	[512]
s31	49	1.0	3696	[512]
s32	49	1.0	3524	[512]

Ahora si sabiendo la frecuencia de muestreo de cada canal, se puede determinar el número total de registros por participante, el tamaño de cada bdf file y la RAM requerida, El resultado se muestra en la tabla 6.

$$\text{total_samples} = \text{num_records} \times \text{samples_per_record} \times \text{num_channels}$$

$$\text{signal_bytes} = \text{total_samples} \times 3$$

$$\text{header_bytes} = 256 + (256 \times \text{num_channels})$$

$$\text{bdf_bytes} = \text{header_bytes} + \text{signal_bytes}$$

$$\text{RAM}_{float32} = \text{total_samples} \times 4$$

Tabla 6: Resumen de duración, tamaño estimado y memoria requerida por participante del dataset DEAP.

Participant	Channels	Record	Records	Duration	Samples	Total registers	BDF size	RAM float32
s01	48	1.0	3869	64.48 min	512	1,980,928	0.266 GB	0.354 GB
s02	48	1.0	3703	61.72 min	512	1,895,936	0.254 GB	0.339 GB
s03	48	1.0	3885	64.75 min	512	1,989,120	0.267 GB	0.356 GB
s04	48	1.0	3301	55.02 min	512	1,690,112	0.227 GB	0.302 GB
s05	48	1.0	3916	65.27 min	512	2,004,992	0.269 GB	0.359 GB
s06	48	1.0	3586	59.77 min	512	1,836,032	0.246 GB	0.328 GB
s07	48	1.0	3571	59.52 min	512	1,828,352	0.245 GB	0.327 GB
s08	48	1.0	3517	58.62 min	512	1,800,704	0.242 GB	0.322 GB
s09	48	1.0	3767	62.78 min	512	1,928,704	0.259 GB	0.345 GB
s10	48	1.0	3512	58.53 min	512	1,798,144	0.241 GB	0.322 GB
s11	48	1.0	4161	69.35 min	512	2,130,432	0.286 GB	0.381 GB
s12	48	1.0	3498	58.30 min	512	1,790,976	0.240 GB	0.320 GB
s13	48	1.0	3711	61.85 min	512	1,900,032	0.255 GB	0.340 GB
s14	48	1.0	3937	65.62 min	512	2,015,744	0.270 GB	0.360 GB
s15	48	1.0	4072	67.87 min	512	2,084,864	0.280 GB	0.373 GB
s16	48	1.0	3683	61.38 min	512	1,885,696	0.253 GB	0.337 GB
s17	48	1.0	3446	57.43 min	512	1,764,352	0.237 GB	0.315 GB
s18	48	1.0	3628	60.47 min	512	1,857,536	0.249 GB	0.332 GB
s19	48	1.0	3746	62.43 min	512	1,917,952	0.257 GB	0.343 GB
s20	48	1.0	3509	58.48 min	512	1,796,608	0.241 GB	0.321 GB
s21	48	1.0	3551	59.18 min	512	1,818,112	0.244 GB	0.325 GB
s22	48	1.0	3719	61.98 min	512	1,904,128	0.255 GB	0.340 GB
s23	48	1.0	3601	60.02 min	512	1,843,712	0.247 GB	0.330 GB
s24	48	1.0	4712	78.53 min	512	2,412,544	0.324 GB	0.431 GB
s25	48	1.0	4120	68.67 min	512	2,109,440	0.283 GB	0.377 GB
s26	48	1.0	3913	65.22 min	512	2,003,456	0.269 GB	0.358 GB
s27	48	1.0	3798	63.30 min	512	1,944,576	0.261 GB	0.348 GB
s28	48	1.0	3527	58.78 min	512	1,805,824	0.242 GB	0.323 GB
s29	49	1.0	3978	66.30 min	512	2,036,736	0.279 GB	0.372 GB
s30	49	1.0	3665	61.08 min	512	1,876,480	0.257 GB	0.343 GB
s31	49	1.0	3696	61.60 min	512	1,892,352	0.259 GB	0.345 GB
s32	49	1.0	3524	58.73 min	512	1,804,288	0.247 GB	0.329 GB
TOTAL						61,348,864	8.251 GB	10.997 GB

El dataset DEAP RAW no presenta una cantidad demasiado pequeña de datos, ya que contiene millones de muestras multicanal registradas a 512 Hz para 32 participantes. Tampoco representa un volumen inmanejable para el hardware actual si se procesa de manera adecuada, aunque cargar simultáneamente todos los archivos completos puede requerir varios GB de RAM, especialmente usando representaciones `float32` o `float64`; por ello, es recomendable trabajar por participante o mediante procesamiento incremental. Respecto a datos duplicados, no se identifican registros duplicados explícitos, ya que cada muestra está asociada a un instante temporal específico dentro de la señal EEG/fisiológica, por lo que incluso valores numéricos iguales corresponden a tiempos distintos y representan observaciones diferentes dentro de la serie temporal.

3.1.3. ¿Qué datos son discretos y cuáles continuos?

Tabla 7: Resumen de canales y propiedades técnicas del dataset DEAP

Channel	Unit(s)	Digital type	Physical type	Digital min	Digital max	Physical min	Physical max	Samples	Available in
Brain channels									
Fp1	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
AF3	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
F7	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
F3	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
FC1	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
FC5	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
T7	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
C3	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
CP1	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
CP5	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
P7	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
P3	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
Pz	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
PO3	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
O1	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
Oz	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
O2	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
PO4	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
P4	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
P8	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
CP6	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
CP2	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
C4	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
T8	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
FC6	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
FC2	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
F4	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
F8	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
AF4	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
Fp2	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
Fz	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
Cz	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
External physiological channels (EXG)									
EXG1	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
EXG2	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
EXG3	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
EXG4	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
EXG5	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
EXG6	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
EXG7	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
EXG8	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
Peripheral physiological channels									
Erg1	[uV]	int24	float32	[-8388608]	[8388607]	[-2097152, -524288]	[2097151, 524286]	[512]	s01-s32
Erg2	[uV]	int24	float32	[-8388608]	[8388607]	[-2097152, -524288]	[2097151, 524286]	[512]	s01-s32
GSR1	[Ohm, nS]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
GSR2	[Ohm, nS]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
Resp	[uV]	int24	float32	[-8388608]	[8388607]	[-262144]	[262143]	[512]	s01-s32
Plet	[uV]	int24	float32	[-8388608]	[8388607]	[-4096000]	[4095875, 4096000]	[512]	s01-s32
Temp	[Celsius, Celsius]	int24	float32	[-8388608]	[8388607]	[-8389]	[8388]	[512]	s01-s32
Status channel									
Status	[Boolean]	int24	float32	[-8388608]	[8388607]	[-8388608]	[8388607]	[512]	s01-s23
	[Boolean]	int24	float32	[-8388608]	[8388607]	[-8388608]	[8388607]	[512]	s24-s32

Se observa que la mayoría de los datos registrados corresponden a señales continuas, ya que representan mediciones fisiológicas temporales como EEG, EOG, EMG, respiración, temperatura y respuesta galvánica, almacenadas digitalmente mediante valores enteros de 24 bits (`int24`) y posteriormente interpretadas como valores físicos en formato `float32`. En contraste, el canal **Status** corresponde a datos discretos o categóricos relacionados con eventos y marcadores experimentales, representados mediante valores booleanos. Los valores digitales son transformados a valores físicos mediante la ecuación de conversión lineal definida por el estándar EDF/BDF, mostrada en la Ecuación 1. Esta transformación se aplica de manera general a todos los canales del dataset,

incluyendo señales EEG, canales fisiológicos periféricos y variables como temperatura o respuesta galvánica, utilizando para cada canal sus respectivos límites digitales y físicos. Respecto a los tipos de datos por columna, los nombres de canales y unidades corresponden a datos de tipo texto, mientras que los límites digitales y físicos representan datos numéricos enteros o reales. Los datos digitales presentan rangos constantes entre -8388608 y 8388607 para todos los canales, mientras que los rangos físicos dependen del tipo de señal fisiológica registrada; por ejemplo, la mayoría de canales EEG utilizan rangos entre -262144 y 262143 μV , mientras que otros canales como **Plet** o **Temp** presentan escalas diferentes. Asimismo, todos los canales mantienen una frecuencia uniforme de 512 muestras por registro, lo que evidencia consistencia temporal entre señales. En general, los datos se encuentran en formatos adecuados para análisis posteriores, aunque se identificaron pequeñas inconsistencias de metadata, como diferencias en el orden de canales y la presencia de un canal con etiqueta vacía en algunos participantes. Finalmente, el dataset utiliza distintas unidades de medida dependiendo del tipo de señal fisiológica, incluyendo microvoltios (μV), ohmios/nanosiemens (**Ohm**, **nS**), grados Celsius y valores booleanos para eventos; todas estas propiedades y rangos técnicos se encuentran resumidos en la Tabla 7.

$$PhysicalValue = \left(\frac{DigitalValue - DigitalMin}{DigitalMax - DigitalMin} \right) (PhysicalMax - PhysicalMin) + PhysicalMin \quad (1)$$

3.1.4. ¿Están todas las filas completas o tenemos campos con valores nulos?

La tabla 8 resume la exploración del dataset que se realizó participante por participante, analizando cada canal de manera individual para verificar consistencia estructural y presencia de valores faltantes. Como resultado, no se identificaron valores nulos en los registros fisiológicos de ninguno de los participantes.

Tabla 8: Resumen de cantidad de canales y valores nulos por participante del dataset DEAP.

Participant	Channels	Nulls
s01	48	0
s02	48	0
s03	48	0
s04	48	0
s05	48	0
s06	48	0
s07	48	0
s08	48	0
s09	48	0
s10	48	0
s11	48	0
s12	48	0
s13	48	0
s14	48	0
s15	48	0
s16	48	0
s17	48	0
s18	48	0
s19	48	0
s20	48	0
s21	48	0
s22	48	0
s23	48	0
s24	48	0
s25	48	0
s26	48	0
s27	48	0
s28	48	0

Participant	Channels	Nulls
s29	49	0
s30	49	0
s31	49	0
s32	49	0

3.2. Online_ratings (.csv file)

La imagen 6 muestra una representación circular de emociones basada en relaciones de similitud psicológica entre distintos estados emocionales. Las emociones cercanas representan estados similares, mientras que las opuestas reflejan emociones contrastantes. Además, la figura organiza las emociones según dimensiones de valencia (negativa/positiva) y control emocional (*low control* vs. *high control*).




Figura 6: Rueda emocional utilizada para representar relaciones de similitud entre distintos estados emocionales, organizada según dimensiones de valencia y control emocional.[2]

El archivo **online_ratings** contiene las evaluaciones individuales recopiladas durante la autoevaluación en línea de los videos emocionales del dataset DEAP. Los participantes calificaron dimensiones emocionales como valencia, arousal y dominancia mediante escalas discretas, además de registrar emociones percibidas utilizando una rueda emocional. La descripción de las columnas principales se presenta en la Tabla 9.

Tabla 9: Descripción de columnas del archivo online ratings

Column name	Descripción
Online_id	Identificador del video correspondiente a la misma columna en el archivo <code>video_list</code> .
Valence	Nivel de valencia emocional registrado (valor entero entre 1 y 9).
Arousal	Nivel de activación emocional registrado (valor entero entre 1 y 9).
Dominance	Nivel de dominancia emocional registrado (valor entero entre 1 y 9).
Wheel_slice	Sección seleccionada en la rueda de emociones. Para algunos participantes, la selección de la rueda emocional no fue registrada correctamente; en dichos casos, el valor de <code>Wheel_slice</code> es 0. En caso contrario, la correspondencia entre emociones y valores enteros es la siguiente: 1. Pride 2. Elation 3. Joy 4. Satisfaction 5. Relief 6. Hope 7. Interest 8. Surprise 9. Sadness 10. Fear 11. Shame 12. Guilt 13. Envy 14. Disgust 15. Contempt 16. Anger
Wheel_strength	Intensidad seleccionada en la rueda emocional (valor entero entre 0=weak y 4=strong).

3.2.1. ¿Qué representa un registro?

Cada registro del archivo `online_ratings` representa la evaluación emocional realizada por un participante para un video específico del dataset DEAP, incluyendo dimensiones afectivas como valencia, arousal y dominancia, así como la emoción percibida e intensidad seleccionadas mediante la rueda emocional.

3.2.2. ¿Cuántos registros hay ?

Tabla 10: Resumen estructural del dataframe `online_ratings`

#	Column	Non-Null Count	Dtype
0	Online_id	1778 non-null	int64
1	Valence	1778 non-null	int64
2	Arousal	1778 non-null	int64
3	Dominance	1778 non-null	int64
4	Wheel_slice	1778 non-null	int64
5	Wheel_strength	1778 non-null	int64

RangeIndex: 1778 entries (0–1777)

Total columns: 6

Data types: int64(6)

Estimated memory usage: 83.5 KB

El archivo `online_ratings.xls` contiene un total de 1778 registros, donde cada registro corresponde a una evaluación emocional realizada sobre un video específico durante la fase de autoevaluación en línea.

3.2.3. ¿Siguen alguna distribución?

La districución la observamos en:

Tabla 11: Estadísticas descriptivas del dataframe `online_ratings`

Statistic	Online_id	Valence	Arousal	Dominance	Wheel_slice	Wheel_strength
count	1778.000000	1778.000000	1778.000000	1778.000000	1778.000000	1778.000000
mean	60.931946	5.320022	4.794713	5.020810	6.925197	2.323397
std	34.424857	2.094679	2.274627	2.097810	4.809427	1.244695
min	1.000000	1.000000	1.000000	1.000000	0.000000	0.000000
25 %	31.000000	4.000000	3.000000	4.000000	3.000000	1.000000
50 %	61.000000	5.000000	5.000000	5.000000	6.500000	2.000000
75 %	91.000000	7.000000	7.000000	6.000000	9.000000	3.000000
max	120.000000	9.000000	9.000000	9.000000	16.000000	4.000000




Figura 7: Distribución de la variable Valence




Figura 8: Distribución de la variable Arousal




Figura 9: Distribución de la variable Dominance

Las variables emocionales **Valence**, **Arousal** y **Dominance** presentan distribuciones discretas dentro del rango 1–9, con mayor concentración de evaluaciones alrededor de valores medios. En particular, las tres variables muestran medianas cercanas a 5 y desviaciones estándar moderadas, lo que sugiere una distribución relativamente balanceada de estímulos emocionales dentro del dataset. Asimismo, se observa una ligera mayor frecuencia en valores medios y medio-altos, especialmente en **Valence** y **Dominance**.

3.2.4. ¿Hay correlación entre features (características)?




Figura 10: Matriz de correlación de las calificaciones online

En la Figura (10) la matriz de correlación muestra relaciones moderadas entre las dimensiones emocionales principales del dataset. En particular, **Valence**, **Arousal** y **Dominance** presentan correlaciones positivas entre sí, indicando que emociones más positivas tienden a asociarse con mayores niveles de activación y sensación de control emocional. Por otro lado, **Wheel_slice** presenta correlaciones negativas respecto a dichas variables, reflejando que distintas regiones de la rueda emocional representan categorías afectivas diferenciadas.

3.3. Participant_ratings (.csv file)

El archivo **participant_ratings** contiene las evaluaciones realizadas por los participantes durante el experimento para cada video presentado. Se registraron dimensiones emocionales como valencia, arousal, dominancia y liking utilizando escalas continuas, mientras que familiarity fue evaluado posteriormente mediante una escala discreta de 5 niveles. Asimismo, el atributo **start_time** almacena el instante temporal de inicio de reproducción de cada estímulo. La descripción de las columnas principales se presenta en la Tabla 12.

Tabla 12: Descripción de columnas del archivo participant ratings

Column name	Descripción
Participant_id	Identificador único del participante (1–32).
Trial	Número del trial, correspondiente al orden de presentación de los estímulos.
Experiment_id	Identificador del video correspondiente a la misma columna en el archivo video_list.
Start_time	Tiempo de inicio de reproducción del video del trial en microsegundos, relativo al inicio del experimento.
Valence	Nivel de valencia emocional registrado (valor decimal entre 1 y 9).
Arousal	Nivel de activación emocional registrado (valor decimal entre 1 y 9).
Dominance	Nivel de dominancia emocional registrado (valor decimal entre 1 y 9).
Liking	Nivel de agrado o preferencia registrado (valor decimal entre 1 y 9).
Familiarity	Nivel de familiaridad con el estímulo presentado (valor entero entre 1 y 5).

3.3.1. ¿Qué representa un registro?

Cada registro del archivo `participant_ratings` representa la evaluación emocional realizada por un participante para un trial específico del experimento, incluyendo el identificador del estímulo presentado, el instante temporal de inicio del video y las valoraciones subjetivas asociadas a dimensiones afectivas como valencia, arousal, dominancia, liking y familiarity.

3.3.2. ¿Cuántos registros hay ?

Tabla 13: Resumen estructural del dataframe `participant_ratings`

#	Column	Non-Null Count	Dtype
0	Participant_id	1280 non-null	int64
1	Trial	1280 non-null	int64
2	Experiment_id	1280 non-null	int64
3	Start_time	1280 non-null	int64
4	Valence	1280 non-null	float64
5	Arousal	1280 non-null	float64
6	Dominance	1280 non-null	float64
7	Liking	1280 non-null	float64
8	Familiarity	1160 non-null	float64

RangeIndex: 1280 entries (0–1279)
Total columns: 9
Data types: float64(5), int64(4)
Estimated memory usage: 90.1 KB

El archivo `participant_ratings.xls` contiene un total de 1280 registros y 9 columnas. Las variables `Valence`, `Arousal`, `Dominance`, `Liking` y `Familiarity` se almacenan como valores continuos de tipo `float64`, mientras que los identificadores y atributos temporales se representan mediante valores enteros (`int64`). Asimismo, la variable `Familiarity` presenta valores faltantes, con únicamente 1160 registros válidos.

3.3.3. ¿Siguen alguna distribución?

La distribucion la observamos en la siguiente tabla 14

Tabla 14: Estadísticas descriptivas del dataframe `participant_ratings`

Statistic	Partic_id	Trial	Exper_id	Start_time	Valence	Arousal	Dominance	Liking	Familiarity
count	1280	1280	1280	1280	1280	1280	1280	1280	1160
mean	16.500000	20.500000	20.500000	2.054696e+07	5.254313	5.156711	5.382750	5.518133	2.347414
std	9.236701	11.547908	11.547908	1.052269e+07	2.130816	2.020499	2.096321	2.282780	1.566747
min	1.000000	1.000000	1.000000	1.695918e+06	1.000000	1.000000	1.000000	1.000000	1.000000
25 %	8.750000	10.750000	10.750000	1.149579e+07	3.867500	3.762500	3.932500	3.960000	1.000000
50 %	16.500000	20.500000	20.500000	2.032845e+07	5.040000	5.230000	5.240000	6.050000	2.000000
75 %	24.250000	30.250000	30.250000	2.959904e+07	7.050000	6.950000	7.040000	7.090000	4.000000
max	32.000000	40.000000	40.000000	4.605244e+07	9.000000	9.000000	9.000000	9.000000	5.000000

Las variables emocionales principales presentan medias cercanas al centro de la escala (5), indicando una distribución relativamente balanceada de respuestas emocionales. En particular, **Liking** presenta la media más alta (5.52), mientras que **Valence**, **Arousal** y **Dominance** muestran desviaciones estándar moderadas, reflejando variabilidad emocional entre participantes y estímulos.




Figura 11: Distribución de la variable Valence




Figura 12: Distribución de la variable Arousal




Figura 13: Distribución de la variable Dominance




Figura 14: Distribución de la variable Liking




Figura 15: Distribución de la variable Familiarity

Las distribuciones de **Valence**, **Arousal**, **Dominance** y **Liking** muestran una mayor concentración de evaluaciones en valores medios y medio-altos de la escala emocional. Por otro lado, la variable **Familiarity** presenta una distribución más desigual, con una fuerte concentración en valores bajos, indicando que muchos participantes reportaron poca familiaridad con los estímulos utilizados.

3.3.4. ¿Existe alguna correlación enter features?




Figura 16: Correlación entre variables emocionales

La matriz de correlación evidencia relaciones positivas entre las variables emocionales principales del dataset. En particular, **Valence** presenta una correlación moderada con **Liking** ($r = 0.62$) y **Dominance** ($r = 0.52$), sugiriendo que estímulos percibidos como más positivos tienden a asociarse con mayor agrado y sensación de control emocional. Asimismo, **Familiarity** presenta correlaciones positivas débiles a moderadas respecto a las demás variables emocionales.

3.4. Participant_questionnaire (.csv file)

El archivo `participant_questionnaire` contiene información complementaria recopilada antes del experimento relacionada con las características de los participantes. Las columnas pueden agruparse en distintas categorías: *Demographic information*, que incluye atributos como `Participant_id`, `Age`, `Gender` y `Education`; *Physiological and perceptual conditions*, con variables como `Handedness`, `Vision`, `Vision Aid`, `Hours of sleep last night`, `Normal hours of sleep` y `Level of Alertness`; *Consumption habits*, que abarca `Alcohol consumption`, `Coffee consumption`, `Black/Green tea consumption`, `Tobacco consumption` y consumo de otras drogas o medicamentos; *Consent information*, relacionada con permisos para distribuir registros fisiológicos y publicaciones audiovisuales; y finalmente *Head measurements*, que incluye medidas antropométricas como `Head circumference`, `Distance Nasion-Inion` y `Distance left-right jaw hinge`, utilizadas en el contexto de adquisición EEG. La descripción detallada de las columnas principales se presenta en la Tabla 15.

Tabla 15: Descripción de columnas del archivo participant questionnaire

Column name	Descripción
Participant_id	Identificador único del participante.
Age	Edad del participante.
Gender	Género del participante.
Handedness	Dominancia manual del participante (diestro o zurdo).
Vision	Condición visual general del participante.
Vision Aid	Tipo de corrección visual utilizada, en caso exista.
Education	Nivel educativo alcanzado por el participante.
Alcohol consumption	Frecuencia o consumo reciente de alcohol.
Coffee consumption	Frecuencia o consumo reciente de café.
Black/Green tea consumption	Frecuencia o consumo reciente de té negro o verde.
Tobacco consumption	Frecuencia o consumo reciente de tabaco.
Other drug/medication consumption (optional)	Consumo de otros medicamentos o sustancias.
Other drug consumption (optional)	Detalle adicional sobre medicamentos o drogas consumidas.
Attention/Neurological/Psychiatric syndroms	Presencia de síndromes neurológicos, psiquiátricos o de atención.
Hours of sleep last night	Cantidad de horas dormidas la noche previa al experimento.
Normal hours of sleep	Promedio habitual de horas de sueño.
Level of Alertness	Nivel de alerta reportado por el participante.
Consent to distribute physiological recordings	Consentimiento para distribuir registros fisiológicos.
Consent to publish audio-visual recordings	Consentimiento para publicar registros audiovisuales.
Head circumference (cm)	Circunferencia de la cabeza en centímetros.
Distance Nasion-Inion (cm)	Distancia entre nasion e inion en centímetros.
Distance left - right jaw hinge (cm)	Distancia entre articulaciones mandibulares izquierda y derecha en centímetros.

3.4.1. ¿Qué representa un registro?

Cada registro del archivo `participant_questionnaire` representa la información demográfica, fisiológica y contextual asociada a un participante específico del experimento, incluyendo características personales, hábitos de consumo, condiciones perceptuales y medidas antropométricas relevantes para la adquisición y análisis de señales EEG.

3.5. Video_list (.csv file)

El archivo `video_list` contiene información descriptiva de los videos utilizados tanto en la autoevaluación en línea como en el experimento principal del dataset DEAP. Entre las columnas incluidas se encuentran identificadores de videos, etiquetas afectivas provenientes de Last.fm, información musical del artista y canción, enlaces originales de YouTube, instantes destacados utilizados durante el experimento y estadísticas derivadas de las evaluaciones emocionales realizadas por los participantes. Asimismo, incorpora estimaciones y clasificaciones relacionadas con dimensiones emocionales de valencia y arousal. La descripción detallada de las principales columnas se presenta en la Tabla 16.

Tabla 16: Descripción de columnas del archivo video list

Column name	Descripción
Online_id	Identificador único utilizado durante la autoevaluación en línea.
Experiment_id	Identificador utilizado dentro del experimento principal. Puede estar vacío si el video no fue seleccionado.
Lastfm_tag	Etiqueta afectiva asociada al video según Last.fm. Puede estar vacía si no existe clasificación.
Artist	Nombre del artista asociado a la canción.
Title	Título de la canción utilizada en el video.
Youtube_link	Enlace original de YouTube desde donde se obtuvo el video.
Highlight_start	Instante en segundos donde inicia el segmento destacado utilizado en el experimento.
Num_ratings	Cantidad de voluntarios que evaluaron el video en la autoevaluación en línea.
VAQ_Estimate	Cuadrante estimado de valencia/arousal asignado por los investigadores: 1. High arousal, high valence 2. Low arousal, high valence 3. Low arousal, low valence 4. High arousal, low valence
VAQ_Online	Cuadrante de valencia/arousal calculado a partir de las evaluaciones promedio de los participantes.
AVG_x, STD_x, Q1_x, Q2_x, Q3_x	Estadísticas descriptivas (promedio, desviación estándar y cuartiles) de las evaluaciones emocionales asociadas a valencia, arousal y dominancia.

3.5.1. ¿Qué representa un registro?

Cada registro del archivo `video_list` representa un video musical utilizado en el dataset DEAP, incluyendo información descriptiva del estímulo audiovisual, etiquetas afectivas asociadas, metadatos musicales y estadísticas derivadas de las evaluaciones emocionales realizadas por los participantes durante la autoevaluación y el experimento principal.

4.2. Hipótesis 2

¿Será que distintos grupos de señales fisiológicas y EEG presentan patrones de relación diferenciables entre participantes durante la exposición a estímulos emocionales?

Esta hipótesis se plantea debido a la naturaleza multimodal del dataset DEAP, el cual combina señales EEG, señales periféricas y canales fisiológicos externos registrados simultáneamente durante estímulos emocionales. Dado que cada participante puede reaccionar de manera distinta frente a un mismo estímulo, resulta relevante explorar si existen relaciones diferenciables entre grupos de señales, tanto a nivel cerebral como fisiológico. Por ejemplo, ciertas respuestas emocionales podrían reflejarse mediante incrementos en actividad electrodérmica, cambios respiratorios o variaciones en regiones específicas del EEG. Esta hipótesis motiva un análisis comparativo e interactivo entre participantes para identificar similitudes, diferencias y posibles patrones multimodales asociados a las respuestas emocionales.




Figura 18: Dashboard Hipótesis 2

4.3. Hipótesis 3

¿Será que las relaciones entre canales EEG y señales de referencia presentan patrones espaciales diferenciables sobre la distribución cerebral del sistema 10–20?

Esta hipótesis se fundamenta en la distribución espacial de los electrodos EEG dentro del sistema internacional 10–20, donde cada canal registra actividad asociada a distintas regiones cerebrales. Debido a que los estímulos emocionales pueden involucrar diferentes procesos cognitivos y fisiológicos, es posible que ciertas zonas cerebrales presenten relaciones más fuertes o diferenciables con señales de referencia como arousal, valencia o señales periféricas. En este contexto, resulta relevante explorar visualmente cómo se distribuyen espacialmente dichas relaciones sobre el mapa cerebral, permitiendo identificar regiones con comportamientos diferenciados y posibles patrones topográficos asociados a la respuesta emocional.



Figura 19: Dashboard Hipótesis 3

Referencias

[1] Koelstra, S., Muhl, C., Soleymani, M., Lee, J.-S., Yazdani, A., Ebrahimi, T., Pun, T., Nijholt, A., y Patras, I., “Deap: A database for emotion analysis; using physiological signals”, IEEE transactions on affective computing, vol. 3, no. 1, pp. 18–31, 2011.

[2] Scherer, K. R., “What are emotions? and how can they be measured?”, Social science information, vol. 44, no. 4, pp. 695–729, 2005.